

„Statistische Modellierung | Fallstudie Student Performance“

Dozent:in, FOM Hochschule

2026-08-11

Inhaltsverzeichnis

Fallstudie Student Performance – Portugiesisch-Kurs	2
1. Erste Schritte	2
1.1 Datentabelle erschließen	2
1.2 Skalenniveau bestimmen	2
1.3 Messung beurteilen	2
2. Explorative Datenanalyse einer kategorialen Variable	2
2.1 Häufigkeitstabelle erstellen	2
2.2 Säulendiagramm erstellen	2
3. Explorative Datenanalyse von G3	2
3.1 Kennwerte berechnen	2
3.2 Histogramm erstellen und interpretieren	3
3.3 Zusammenhang zwischen freetime und G3	3
4. Inferenzstatistik	3
4.1 Bootstrap für den Mittelwert von G3	3
4.2 Histogramm der Bootstrap-Verteilung	3
4.3 Mittelwertvergleich für internet	3
4.4 Permutationsverteilung für internet	3
4.5 Bootstrap für die Korrelation zwischen absences und G3	4
4.6 Histogramm der Bootstrap-Korrelationen	4
5. Bayes-Statistik	4
5.1 Binäre Variable pass erzeugen	4
5.2 Informative Priori-Verteilung darstellen	4
5.3 Likelihood-Funktion darstellen	4
5.4 Posteriori-Verteilung bestimmen	4
5.5 Priorvergleich durchführen	4
6. Lineare Regression	4
6.1 Einfache lineare Regression	4
6.2 Multiple lineare Regression	5
6.3 Interaktionsmodell	5
7. Kausale Modellierung	5
7.1 Naives Modell für paid	5
7.2 Adjustiertes Modell für paid	5
8. Random Forest	6
8.1 Random Forest schätzen	6
8.2 Modellgüte bewerten	6
8.3 Variablenwichtigkeit interpretieren	6

```
# benötigte Pakete laden
library(mosaic)
library(psych)
library(tidyr)
library(here)
library(caret)
library(randomForest)
library(corrplot)
library(dplyr)
library(tidyverse)

# Datentabelle einlesen
student <- read.csv(here("data", "student-por-clean.csv"))
```

Fallstudie Student Performance – Portugiesisch-Kurs

1. Erste Schritte

1.1 Datentabelle erschließen

Für diese Fallstudie arbeiten Sie mit Daten zum schulischen Leistungsverhalten von Schülerinnen und Schülern einer portugiesischen Sekundarschule. Bevor Sie mit den eigentlichen Analysen beginnen, soll zunächst die Datenbasis systematisch erschlossen werden. Ermitteln Sie, wie viele Beobachtungen und wie viele Variablen die Datentabelle enthält. Nennen Sie außerdem die in der Datentabelle enthaltenen Variablen und beschreiben Sie die Beobachtungseinheit.

1.2 Skalenniveau bestimmen

Bestimmen Sie für die Variablen `studytime`, `absences`, `internet`, `higher`, `sex`, `G3`, `famrel`, `goout`, `health` und `freetime` jeweils das Skalenniveau und beschreiben Sie die Information der Variable.

1.3 Messung beurteilen

Beurteilen Sie die Variablen `studytime`, `famrel`, `goout` und `health` im Hinblick auf mögliche Messprobleme. Gehen Sie dabei insbesondere auf die Vergleichbarkeit der Antwortkategorien, mögliche Validitätsprobleme und Verzerrungen ein.

2. Explorative Datenanalyse einer kategorialen Variable

2.1 Häufigkeitstabelle erstellen

Analysieren Sie ausschließlich die Variable `higher`; die Variable beschreibt, ob eine Person eine höhere Bildung anstrebt. Erstellen Sie eine relative und eine absolute Häufigkeitstabelle, die die jeweiligen Werte jeder Kategorie der Variable enthält. Erläutern Sie außerdem, welche Folgen die ungleiche Häufigkeit der beiden Kategorien für spätere Analysen haben könnte.

2.2 Säulendiagramm erstellen

Erstellen Sie ein Säulendiagramm der absoluten Häufigkeiten von `higher`. Beschreiben Sie die Verteilung von `higher` auf Basis der Tabelle und des Säulendiagramms. Gehen Sie dabei insbesondere auf die häufigere Kategorie und die generelle Verteilung ein.

3. Explorative Datenanalyse von G3

3.1 Kennwerte berechnen

Analysieren Sie als Nächstes die Variable `G3`, welche die Abschlussnote im Fach „Portugiesisch“ beschreibt. Berechnen Sie für `G3` die folgenden Kennwerte: Mittelwert, Median, Standardabweichung, Minimum, Maximum, 25%-Quantil, 75%-Quantil und Interquartilsabstand. Interpretieren Sie die Werte anschließend.

3.2 Histogramm erstellen und interpretieren

Erstellen Sie ein Histogramm von G3 und beschreiben Sie anschließend, welche Form die Verteilung aufweist. Gehen Sie dabei insbesondere auf Schiefe sowie auf die Frage ein, in welchen Wertebereichen sich viele beziehungsweise wenige Beobachtungen befinden. Benennen Sie den Modus.

3.3 Zusammenhang zwischen freetime und G3

Untersuchen Sie den Zusammenhang zwischen freetime und G3.

Die Variable freetime ist ordinal skaliert und umfasst fünf geordnete Kategorien von „sehr niedrig“ bis „sehr hoch“. Für die folgende Analyse wird sie vereinfachend als quasi-metrisch behandelt. Diese Annahme bedeutet, dass die Abstände zwischen benachbarten Antwortkategorien näherungsweise als vergleichbar interpretiert werden.

Erstellen Sie ein Streudiagramm und berechnen Sie die Pearson-Korrelation. Bestimmen Sie ergänzend die Spearman-Rangkorrelation und beurteilen Sie, ob beide Kennwerte zu einer vergleichbaren inhaltlichen Schlussfolgerung führen. Die Spearman-Rangkorrelation wird ergänzend berechnet, um zu prüfen, ob die inhaltliche Schlussfolgerung auch dann bestehen bleibt, wenn freetime nicht quasi-metrisch, sondern ausschließlich entsprechend seiner ordinalen Rangordnung berücksichtigt wird. Fallen Pearson- und Spearman-Korrelation ähnlich aus, spricht dies dafür, dass der festgestellte Zusammenhang nicht wesentlich von der Annahme gleich großer Abstände zwischen den Kategorien von freetime abhängt.

4. Inferenzstatistik

4.1 Bootstrap für den Mittelwert von G3

Bestimmen Sie für den Mittelwert von G3 mithilfe des Bootstrap-Verfahrens den Standardfehler und ein 95%-Konfidenzintervall.

4.2 Histogramm der Bootstrap-Verteilung

Stellen Sie die Bootstrap-Verteilung der Mittelwerte grafisch dar. Markieren Sie den beobachteten Stichprobenmittelwert sowie die untere und obere Grenze des 95%-Konfidenzintervalls. Beschreiben Sie die Form und Streuung der Bootstrap-Verteilung.

4.3 Mittelwertvergleich für internet

Untersuchen Sie mithilfe einer linearen Regression, ob sich die mittlere Abschlussnote G3 in der vorliegenden Stichprobe zwischen Schülerinnen und Schülern mit und ohne Internetzugang zu Hause unterscheidet.

Verwenden Sie internet = no als Referenzgruppe. Geben Sie den geschätzten Mittelwert der Referenzgruppe sowie die geschätzte Mittelwertdifferenz für internet = yes an.

Bestimmen Sie außerdem ein 95%-Konfidenzintervall für die Mittelwertdifferenz und beurteilen Sie anhand des Intervalls und des p-Werts, ob ein mittlerer Unterschied von 0 Punkten mit den Daten vereinbar ist. Formulieren Sie die Nullhypothese und die zweiseitige Alternativhypothese.

4.4 Permutationsverteilung für internet

Formulieren Sie für den Koeffizienten von internet im linearen Regressionsmodell $G3 \sim \text{internet}$ die Nullhypothese und die Alternativhypothese. Erzeugen Sie anschließend eine Permutationsverteilung für diesen Koeffizienten, bestimmen Sie den p-Wert und treffen Sie eine Entscheidung auf einem Signifikanzniveau von 5%. Gehen Sie davon aus, dass unter der Nullhypothese kein Zusammenhang besteht und die Gruppenzugehörigkeit zufällig ist. Mischen Sie daher die Variable internet mehrfach neu, während die Noten gleich bleiben, und berechnen Sie jeweils den Koeffizienten des linearen Modells. Visualisieren Sie die resultierende Permutationsverteilung in einem Histogramm und markieren Sie den beobachteten Koeffizienten, um seine Lage im Vergleich zur Nullverteilung zu beurteilen.

4.5 Bootstrap für die Korrelation zwischen absences und G3

Bestimmen Sie für die Pearson-Korrelation zwischen der Anzahl der Fehlzeiten absences und der Abschlussnote G3 die beobachtete Korrelation. Schätzen Sie anschließend mithilfe eines Bootstrap-Verfahrens den Standardfehler der Korrelation und bestimmen Sie ein 95%-Konfidenzintervall.

Interpretieren Sie die Richtung und Stärke des Zusammenhangs. Erläutern Sie außerdem, was der Bootstrap-Standardfehler über die Unsicherheit der Korrelationsschätzung aussagt, und beurteilen Sie anhand des Konfidenzintervalls, ob ein fehlender linearer Zusammenhang mit den Daten vereinbar ist.

4.6 Histogramm der Bootstrap-Korrelationen

Stellen Sie die Bootstrap-Verteilung der Pearson-Korrelationen zwischen der Anzahl der Fehlzeiten absences und der Abschlussnote G3 grafisch dar. Markieren Sie die beobachtete Korrelation sowie die untere und obere Grenze des 95%-Konfidenzintervalls.

5. Bayes-Statistik

5.1 Binäre Variable pass erzeugen

Erzeugen Sie aus G3 die binäre Variable pass, wobei $G3 \geq 10$ als bestanden gilt. Lassen Sie sich anschließend die absoluten und relativen Häufigkeiten ausgeben und bestimmen Sie den Erfolgsanteil. Formulieren Sie im Text, wie viele Schülerinnen und Schüler bestanden haben und welcher Anteil der Stichprobe dies ist.

5.2 Informative Priori-Verteilung darstellen

Die portugiesische Statistikbehörde berichtet für aktuelle Abschlussprüfungen eine Bestehensquote von ungefähr 91,2% (vgl. Kennzahlenseite des INE¹). Für die Fallstudie soll dieser externe Wert leicht gerundet als Vorannahme verwendet werden.

Legen Sie für den Erfolgsanteil der bestandenen Schülerinnen und Schüler eine informative Beta-Priori-Verteilung fest, deren Erwartungswert bei 0,90 bei insgesamt 20 Pseudo-Beobachtungen liegt, und stellen Sie diese grafisch dar. Begründen Sie kurz, wie sich die gewählte Priori-Verteilung an der externen Bestehensquote orientiert.

5.3 Likelihood-Funktion darstellen

Stellen Sie die Likelihood-Funktion für den Erfolgsanteil π auf Basis der beobachteten Daten zu pass dar und bestimmen Sie den Maximum-Likelihood-Schätzer. Stellen Sie die Likelihood-Funktion zusätzlich als Grafik dar und markieren Sie den Maximum-Likelihood-Schätzer grafisch.

5.4 Posteriori-Verteilung bestimmen

Bestimmen Sie auf Basis der Daten die Posteriori-Verteilung sowie den Posterior-Modus und ein 95%-Kreditätsintervall.

5.5 Priorvergleich durchführen

Vergleichen Sie die Auswirkungen der informativen Prior-Verteilung $\text{Beta}(18, 2)$ mit einer uniformen Prior $\text{Beta}(1, 1)$, indem Sie beide Posteriori-Verteilungen grafisch darstellen. Beschreiben Sie, ob und wie sich die Posteriori-Verteilungen voneinander unterscheiden und welche Rolle die große Stichprobe für die Bedeutung der Priorwahl spielt.

6. Lineare Regression

6.1 Einfache lineare Regression

Untersuchen Sie, ob ein linearer Zusammenhang zwischen der Anzahl der Fehlzeiten absences und der Abschlussnote G3 besteht.

¹Instituto Nacional de Estatística (INE), Kennzahlenseite zur Bestehensquote: https://www.ine.pt/xportal/xmain?xpid=INE&xpgid=ine_indicadores&indOcorrCod=0012635&contexto=bd&selTab=tab2

Formulieren Sie zunächst eine Forschungsfrage sowie eine Null- und eine zweiseitige Alternativhypothese. Schätzen Sie das lineare Regressionsmodell $G3 \sim \text{absences}$ und interpretieren Sie die wichtigsten Ergebnisse. Beurteilen Sie anhand des p-Werts, ob der Regressionskoeffizient von `absences` statistisch von 0 unterscheidbar ist. Geben Sie außerdem das Bestimmtheitsmaß an und nehmen Sie eine Punktprognose für eine Schülerin bzw. einen Schüler vor, die bzw. der 5 Fehlzeiten aufweist.

6.2 Multiple linear Regression

Untersuchen Sie, ob die Anzahl der Fehlzeiten `absences`, die freie Zeit nach der Schule `freetime` und der Internetzugang zu Hause `internet` gemeinsam mit der Abschlussnote `G3` zusammenhängen.

Formulieren Sie zunächst eine Forschungsfrage sowie eine Null- und eine Alternativhypothese für das Gesamtmodell. Schätzen Sie das multiple lineare Regressionsmodell $G3 \sim \text{absences} + \text{freetime} + \text{internet}$.

Interpretieren Sie den Achsenabschnitt und alle Regressionskoeffizienten unter Konstanthaltung der jeweils übrigen Variablen. Beurteilen Sie anhand der p-Werte, ob die einzelnen Koeffizienten statistisch von 0 unterscheidbar sind. Berichten und interpretieren Sie außerdem das Bestimmtheitsmaß.

Die Variable `freetime` ist ordinal skaliert und umfasst ursprünglich die Werte 1 bis 5. Kodieren Sie `freetime` für die Regression so um, dass 0 der niedrigsten Ausprägung entspricht. Für das Modell wird `freetime` vereinfachend als quasi-metrische Variable behandelt. Machen Sie deutlich, welche Annahme damit verbunden ist.

6.3 Interaktionsmodell

Untersuchen Sie, ob sich der lineare Zusammenhang zwischen der Anzahl der Fehlzeiten `absences` und der Abschlussnote `G3` je nach Ausprägung der freien Zeit nach der Schule `freetime` unterscheidet.

Formulieren Sie eine Forschungsfrage sowie eine Null- und eine Alternativhypothese für den Interaktionsterm zwischen `absences` und `freetime`.

Schätzen Sie das Interaktionsmodell und interpretieren Sie den Achsenabschnitt und alle Regressionskoeffizienten, insbesondere den Interaktionsterm `absences : freetime`. Begründen Sie Ihre Aussage zur Bedeutung der Interaktion sowohl anhand des p-Werts des Interaktionsterms als auch anhand des Bestimmtheitsmaßes.

7. Kausale Modellierung

7.1 Naives Modell für `paid`

Schätzen Sie ein bivariates Modell für den Zusammenhang zwischen `paid`, also bezahlter Nachhilfe, und der Abschlussnote `G3`. Erstellen Sie zuvor ein DAG, das diesen Zusammenhang beschreibt. Das zugehörige DAG kann auf der Website DAGitty.net grafisch erstellt werden.

7.2 Adjustiertes Modell für `paid`

Schätzen Sie ein adjustiertes Modell für den Zusammenhang zwischen bezahlter Nachhilfe `paid` und der Abschlussnote `G3`, in dem Sie zusätzlich `freetime`, `absences`, `failures` und `highers` berücksichtigen. Erstellen Sie zuvor ein DAG mit den angenommenen theoretischen Zusammenhängen.

Formulieren Sie eine Forschungsfrage sowie eine Null- und eine Alternativhypothese für den Koeffizienten von `paidyes`. Stellen Sie die Regressionsgleichung des adjustierten Modells explizit auf.

Interpretieren Sie den Achsenabschnitt und die Regressionskoeffizienten für `paidyes`, `freetime`, `absences`, `failures` und `highers` jeweils als erwartete Änderung von `G3` bei einer Änderung der jeweiligen Variablen, unter Konstanthaltung der übrigen. Beurteilen Sie anhand der p-Werte, ob die einzelnen Koeffizienten statistisch von 0 unterscheidbar sind, und berichten Sie das Bestimmtheitsmaß sowie den F-Test für das Gesamtmodell.

Hinweis: Das Modell liefert einen adjustierten assoziativen Zusammenhang unter den Annahmen des DAG. Es erlaubt ohne zusätzliche Voraussetzungen keine eindeutige kausale Aussage über die Wirkung von bezahlter Nachhilfe.

8. Random Forest

8.1 Random Forest schätzen

Schätzen Sie einen Random Forest zur Vorhersage von `pass`. Schließen Sie `G1` und `G2` aus. Trainieren Sie den Random Forest auf 80 Prozent der Daten und testen Sie auf 20 Prozent der Daten. Durch den Ausschluss von `G1` und `G2` soll vermieden werden, dass frühere Noten die Vorhersage von `pass` nahezu vollständig dominieren. Trotzdem stehen noch zahlreiche schulische und soziale Merkmale zur Verfügung, sodass das Modell potenziell komplexe nichtlineare Zusammenhänge nutzen kann.

Da `randomForest()` fehlende Prädiktorwerte nicht ohne Weiteres verarbeitet, wird vor dem Modelltraining explizit auf fehlende Werte geprüft. Im verwendeten vorab gecleanten Datensatz liegen keine fehlenden Werte vor; in einer realen Anwendung wäre dieser Schritt jedoch zwingend notwendig. Es wird ein Random Forest mit Standardparametern geschätzt. Dies ist eine bewusste didaktische Vereinfachung, um das Grundprinzip von Random Forests zu illustrieren, ohne die Komplexität durch Hyperparameter-Tuning zu erhöhen.

Beurteilen Sie die Vorhersagegüte anhand der OOB-Fehlerrate (interne Validierung während des Trainings) und der Konfusionsmatrix auf den Testdaten (externe Beurteilung). Erläutern Sie, ob das Modell beide Klassen (`yes` und `no`) gleichermaßen gut vorhersagt, und gehen Sie dabei auf die Unausgewogenheit der Klassen ein.

8.2 Modellgüte bewerten

Bewerten Sie die Güte des Random-Forest-Modells auf den Testdaten. Heben Sie dabei hervor, welche Gütekennzahlen bei starker Klassenungleichheit besonders aussagekräftig sind, und grenzen Sie die externe Testgüte von der internen OOB-Fehlerrate ab.

8.3 Variablenwichtigkeit interpretieren

Geben Sie die wichtigsten Prädiktoren des Random Forest aus und interpretieren Sie die Ergebnisse der Variablenwichtigkeit. Machen Sie deutlich, dass sich die Wichtigkeit ausschließlich auf den Beitrag zur Vorhersagegüte in diesem konkreten Modell bezieht und keine kausale Relevanz ausdrückt.