

Statistische Modellierung | Fallstudie Student Performance – Musterlösung

Dozent:in, FOM Hochschule

2026-08-11

Inhaltsverzeichnis

Fallstudie Student Performance – Portugiesisch-Kurs	2
1. Erste Schritte	2
1.1 Datentabelle erschließen	2
1.2 Skalenniveau bestimmen	3
1.3 Messung beurteilen	4
2. Explorative Datenanalyse einer kategorialen Variable	4
2.1 Häufigkeitstabelle erstellen	4
2.2 Säulendiagramm erstellen	5
3. Explorative Datenanalyse von G3	6
3.1 Kennwerte berechnen	6
3.2 Histogramm erstellen und interpretieren	7
3.3 Zusammenhang zwischen freetime und G3	8
4. Inferenzstatistik	9
4.1 Bootstrap für den Mittelwert von G3	9
4.2 Histogramm der Bootstrap-Verteilung	10
4.3 Mittelwertvergleich für internet	11
4.4 Permutationsverteilung für internet	12
4.5 Bootstrap für die Korrelation zwischen absences und G3	14
4.6 Histogramm der Bootstrap-Korrelationen	15
5. Bayes-Statistik	16
5.1 Binäre Variable pass erzeugen	16
5.2 Informative Priori-Verteilung darstellen	17
5.3 Likelihood-Funktion darstellen	18
5.4 Posteriori-Verteilung bestimmen	20
5.5 Priorvergleich durchführen	22
6. Lineare Regression	23
6.1 Einfache lineare Regression	23
6.2 Multiple lineare Regression	25
6.3 Interaktionsmodell	26
7. Kausale Modellierung	28
7.1 Naives Modell für paid	28
7.2 Adjustiertes Modell für paid	29
8. Random Forest	32
8.1 Random Forest schätzen	32
8.2 Modellgüte bewerten	34
8.3 Variablenwichtigkeit interpretieren	35

```
# benötigte Pakete laden
library(mosaic)
library(psych)
library(tidyr)
library(here)
library(caret)
library(randomForest)
library(corrplot)
library(dplyr)
library(tidyverse)

# Datentabelle einlesen
student <- read.csv(here("data", "student-por-clean.csv"))
```

Fallstudie Student Performance – Portugiesisch-Kurs

1. Erste Schritte

1.1 Datentabelle erschließen

Für diese Fallstudie arbeiten Sie mit Daten zum schulischen Leistungsverhalten von Schülerinnen und Schülern einer portugiesischen Sekundarschule. Bevor Sie mit den eigentlichen Analysen beginnen, soll zunächst die Datenbasis systematisch erschlossen werden. Ermitteln Sie, wie viele Beobachtungen und wie viele Variablen die Datentabelle enthält. Nennen Sie außerdem die in der Datentabelle enthaltenen Variablen und beschreiben Sie die Beobachtungseinheit.

```
# Struktur der Datentabelle anzeigen
str(student)
```

```
'data.frame': 649 obs. of 19 variables:
 $ school : chr "GP" "GP" "GP" "GP" ...
 $ sex : chr "F" "F" "F" "F" ...
 $ Medu : int 4 1 1 4 3 4 2 4 3 3 ...
 $ Fedu : int 4 1 1 2 3 3 2 4 2 4 ...
 $ studytime: int 2 2 2 3 2 2 2 2 2 2 ...
 $ failures : int 0 0 0 0 0 0 0 0 0 0 ...
 $ paid : chr "no" "no" "no" "no" ...
 $ higher : chr "yes" "yes" "yes" "yes" ...
 $ internet : chr "no" "yes" "yes" "yes" ...
 $ famrel : int 4 5 4 3 4 5 4 4 4 5 ...
 $ freetime : int 3 3 3 2 3 4 4 1 2 5 ...
 $ goout : int 4 3 2 2 2 2 4 4 2 1 ...
 $ Walc : int 1 1 3 1 2 2 1 1 1 1 ...
 $ health : int 3 3 3 5 5 5 3 1 1 5 ...
 $ absences : int 4 2 6 0 0 6 0 2 0 0 ...
 $ G1 : int 0 9 12 14 11 12 13 10 15 12 ...
 $ G2 : int 11 11 13 14 13 12 12 13 16 12 ...
 $ G3 : int 11 11 12 14 13 13 13 13 17 13 ...
 $ course : chr "por" "por" "por" "por" ...
```

```
# erste Fälle der Datentabelle anzeigen
head(student)
```

	school	sex	Medu	Fedu	studytime	failures	paid	higher	internet	famrel	freetime
1	GP	F	4	4	2	0	no	yes	no	4	3
2	GP	F	1	1	2	0	no	yes	yes	5	3
3	GP	F	1	1	2	0	no	yes	yes	4	3
4	GP	F	4	2	3	0	no	yes	yes	3	2
5	GP	F	3	3	2	0	no	yes	no	4	3
6	GP	M	4	3	2	0	no	yes	yes	5	4

	goout	Walc	health	absences	G1	G2	G3	course
1	4	1	3	4	0	11	11	por
2	3	1	3	2	9	11	11	por
3	2	3	3	6	12	13	12	por
4	2	1	5	0	14	14	14	por
5	2	2	5	0	11	13	13	por
6	2	2	5	6	12	12	13	por

```
# Anzahl der Beobachtungen bestimmen
nrow(student)
```

```
[1] 649
```

```
# Anzahl der Variablen bestimmen
ncol(student)
```

```
[1] 19
```

```
# Variablennamen ausgeben
names(student)
```

```
[1] "school" "sex" "Medu" "Fedu" "studytime" "failures"
[7] "paid" "higher" "internet" "famrel" "freetime" "goout"
[13] "Walc" "health" "absences" "G1" "G2" "G3"
[19] "course"
```

Die Datentabelle umfasst 649 Beobachtungen und 19 Variablen; enthalten sind school, sex, Medu, Fedu, studytime, failures, paid, higher, internet, famrel, freetime, goout, Walc, health, absences, G1, G2, G3 und course. Die Beobachtungseinheit ist jeweils eine einzelne Schülerin bzw. ein einzelner Schüler, da jede Zeile genau eine Person mit ihren Merkmalsausprägungen beschreibt.

1.2 Skalenniveau bestimmen

Bestimmen Sie für die Variablen studytime, absences, internet, higher, sex, G3, famrel, goout, health und freetime jeweils das Skalenniveau und beschreiben Sie die Information der Variable.

- studytime: kategorial, ordinalskaliert; die Variable gibt die wöchentliche Lernzeit in geordneten Kategorien an: 1 = < 2 Stunden, 2 = 2 bis 5 Stunden, 3 = 5 bis 10 Stunden, 4 = > 10 Stunden.
- absences: metrisch, verhältnisskaliert; die Variable beschreibt die Anzahl der Fehlzeiten.
- internet: kategorial, nominalskaliert; die Variable gibt an, ob zu Hause Internetzugang vorhanden ist, mit den Ausprägungen yes und no.
- higher: kategorial, nominalskaliert; die Variable beschreibt, ob eine Person eine höhere Bildung anstrebt, mit den Ausprägungen yes und no.
- sex: kategorial, nominalskaliert; die Variable beschreibt das Geschlecht mit den Ausprägungen F = weiblich und M = männlich.

- G3: metrisch, im Folgenden intervallskaliert behandelt; die Variable enthält die Abschlussnote im Portugiesisch-Kurs.
- famrel: kategorial, ordinalskaliert; die Variable beschreibt die Qualität der Familienbeziehungen auf einer geordneten Skala von 1 = sehr schlecht bis 5 = ausgezeichnet.
- goout: kategorial, ordinalskaliert; die Variable gibt an, wie häufig eine Person mit Freundinnen und Freunden ausgeht, auf einer Skala von 1 = sehr selten bis 5 = sehr häufig.
- health: kategorial, ordinalskaliert; die Variable beschreibt den aktuellen Gesundheitszustand auf einer geordneten Skala von 1 = sehr schlecht bis 5 = sehr gut.
- freetime: kategorial, ordinalskaliert; die Variable beschreibt die verfügbare freie Zeit nach der Schule auf einer geordneten Skala von 1 = sehr gering bis 5 = sehr hoch.

1.3 Messung beurteilen

Beurteilen Sie die Variablen `studytime`, `famrel`, `goout` und `health` im Hinblick auf mögliche Messprobleme. Gehen Sie dabei insbesondere auf die Vergleichbarkeit der Antwortkategorien, mögliche Validitätsprobleme und Verzerrungen ein.

`studytime` erfasst die wöchentliche Lernzeit lediglich in vier geordneten Kategorien. Dadurch bleiben Unterschiede innerhalb einer Kategorie unbeobachtet. Zudem sind die Antwortkategorien an ihren Grenzen nicht vollständig distinkt: Die Kategorien „2 bis 5 Stunden“ und „5 bis 10 Stunden“ überlappen sich bei genau fünf Stunden. Damit ist nicht eindeutig, welcher Kategorie eine Person mit fünf Stunden Lernzeit zuzuordnen ist. Die Kategorien bilden außerdem unterschiedlich breite Zeitintervalle ab und sind daher nicht ohne Weiteres messäquivalent.

Als Selbstauskunft kann `studytime` zudem verzerrt sein. Die Befragten müssen ihren Lernaufwand einschätzen und sich gegebenenfalls rückblickend daran erinnern. Dabei können nicht nur Erinnerungslücken, sondern auch systematische Erinnerungseffekte auftreten, etwa eine Über- oder Unterschätzung der tatsächlich investierten Lernzeit. Zusätzlich kann soziale Erwünschtheit dazu führen, dass ein höherer Lernaufwand angegeben wird, als tatsächlich vorliegt.

Die Variablen `famrel` und `goout` beruhen ebenfalls auf subjektiven Selbsteinschätzungen. Es wird kein konkreter Bezugszeitraum genannt. Daher bleibt beispielsweise offen, ob die Befragten ihre aktuelle, typische oder längerfristige familiäre Beziehungssituation beziehungsweise ihr Ausgehverhalten beurteilen sollen. Unterschiedliche Personen können dieselbe Antwortkategorie außerdem unterschiedlich interpretieren. Auch soziale Erwünschtheit kann die Antworten beeinflussen, etwa wenn besonders harmonische Familienbeziehungen oder ein sozial erwünschtes Ausgehverhalten berichtet werden.

Bei `health` ist zwar ein „aktueller“ Gesundheitszustand gemeint, der Zeitraum von „aktuell“ bleibt jedoch undefiniert. Die Befragten können darunter ihren Zustand am Befragungstag, in den vergangenen Tagen oder ihre allgemeine gesundheitliche Verfassung verstehen. Zusätzlich ist die Selbsteinschätzung des Gesundheitszustands anfällig für systematische Verzerrungen: Ein Selbstaufwertungs- oder Optimismusbias kann dazu führen, dass Personen ihren Gesundheitszustand besser bewerten, als er objektiv wäre. Umgekehrt ist auch eine stärker problemorientierte oder beschwerdebetonte Einschätzung denkbar, bei der gesundheitliche Probleme überbetont werden. Die Richtung dieser Verzerrung ist somit nicht eindeutig und schwer zu kontrollieren.

Insgesamt sind die Variablen für explorative Analysen nutzbar. Ihre Ergebnisse sollten jedoch als Auswertungen grober und potenziell verzerrter Selbstberichte interpretiert werden. Insbesondere sollten die Kategorien nicht ohne weitere Begründung als gleich weit voneinander entfernt verstanden werden.

2. Explorative Datenanalyse einer kategorialen Variable

2.1 Häufigkeitstabelle erstellen

Analysieren Sie ausschließlich die Variable `higher`; die Variable beschreibt, ob eine Person eine höhere Bildung anstrebt. Erstellen Sie eine relative und eine absolute Häufigkeitstabelle, die die jeweiligen Werte

jeder Kategorie der Variable enthält. Erläutern Sie außerdem, welche Folgen die ungleiche Häufigkeit der beiden Kategorien für spätere Analysen haben könnte.

```
# Absolute Häufigkeiten von higher berechnen
higherabs <- tally(~ higher, data = student)

# Relative Häufigkeiten von higher berechnen
higherrel <- tally(~ higher, data = student, format = "proportion")

# Ausgabe
higherabs
```

```
higher
no yes
69 580
```

```
higherrel
```


```
higher
      no      yes
0.1063174 0.8936826
```

Die Variable `higher` ist in der Stichprobe sehr unausgewogen verteilt. Von 649 Schülerinnen und Schülern geben 580 Personen (89,37 Prozent) an, eine höhere Bildung anzustreben, während nur 69 Personen (10,63 Prozent) dies verneinen. Für spätere Analysen bedeutet die unausgewogene Verteilung, dass Ergebnisse zur kleinen Kategorie `no` auf vergleichsweise wenigen Fällen beruhen. Unterschiede oder Vorhersagen für diese Gruppe können daher unsicherer sein. Insbesondere bei Klassifikationsmodellen kann eine hohe Gesamtgüte entstehen, obwohl die seltenere Kategorie nur unzureichend erkannt wird.

2.2 Säulendiagramm erstellen

Erstellen Sie ein Säulendiagramm der absoluten Häufigkeiten von `higher`. Beschreiben Sie die Verteilung von `higher` auf Basis der Tabelle und des Säulendiagramms. Gehen Sie dabei insbesondere auf die häufigere Kategorie und die generelle Verteilung ein.

```
# Säulendiagramm der absoluten Häufigkeiten von higher erstellen
gf_bar(~ higher, data = student)
```



Das Säulendiagramm macht die starke Dominanz der Kategorie yes unmittelbar sichtbar. Der Balken für yes ist mit 580 Fällen mehr als achtmal so hoch wie der Balken für no mit 69 Fällen. Grafisch zeigt sich damit, dass der Wunsch nach höherer Bildung in dieser Stichprobe der Regelfall ist. Mit einem Anteil von 89,37 Prozent ist die Verteilung deutlich auf eine Kategorie konzentriert. Inhaltlich spricht das dafür, dass Bildungsaspirationen in dieser Gruppe sehr verbreitet sind und nur eine kleine Minderheit keine höhere Bildung anstrebt.

3. Explorative Datenanalyse von G3

3.1 Kennwerte berechnen

Analysieren Sie als Nächstes die Variable G3, welche die Abschlussnote im Fach „Portugiesisch“ beschreibt. Berechnen Sie für G3 die folgenden Kennwerte: Mittelwert, Median, Standardabweichung, Minimum, Maximum, 25%-Quantil, 75%-Quantil und Interquartilsabstand. Interpretieren Sie die Werte anschließend.

```
# Zentrale Kennwerte für G3 berechnen
g3stats <- favstats(~ G3, data = student)
g3stats
```

```
min Q1 median Q3 max      mean      sd    n missing
  0 10     12 14  19 11.90601 3.230656 649      0
```

```
# Interquartilsabstand berechnen
iqr(~ G3, data = student)
```


```
[1] 4
```

Die Abschlussnote G3 hat einen Mittelwert von 11,91, einen Median von 12 und eine Standardabweichung von 3,23. Die Werte reichen von 0 bis 19 Punkten; das 25%-Quantil liegt bei 10 und das 75%-Quantil bei 14, sodass der Interquartilsabstand 4 Punkte beträgt. Damit liegen die mittleren 50 Prozent der Abschlussnoten zwischen 10 und 14 Punkten, also grob im mittleren bis leicht oberen Leistungsbereich.

3.2 Histogramm erstellen und interpretieren

Erstellen Sie ein Histogramm von G3 und beschreiben Sie anschließend, welche Form die Verteilung aufweist. Gehen Sie dabei insbesondere auf Schiefe sowie auf die Frage ein, in welchen Wertebereichen sich viele beziehungsweise wenige Beobachtungen befinden. Benennen Sie den Modus.

```
# Histogramm zur Verteilung von G3 erstellen
gf_histogram(~ G3, data = student, bins = 20)
```



```
# Schiefe ergänzend berechnen
skew(student$G3)
```

```
[1] -0.9086938
```

```
# Modus von G3 bestimmen
g3_haeufigkeiten <- tally(~ G3, data = student)
g3_haeufigkeiten
```

```
G3
 0  1  5  6  7  8  9 10 11 12 13 14 15 16 17 18 19
15  1  1  3 10 35 35 97 104 72 82 63 49 36 29 15  2
```

```
modus_g3 <- as.numeric(names(g3_haeufigkeiten)[
  which.max(g3_haeufigkeiten)
])
modus_g3
```

```
[1] 11
```

Die Verteilung von G3 ist nicht perfekt symmetrisch, sondern moderat linksschief mit einer Schiefe von -0,909. Der Modus liegt bei 11 Punkten und tritt mit 104 Beobachtungen am häufigsten auf. Deutlich mehr

als die Hälfte der Beobachtungen haben eine Note von 10 oder höher. Das theoretische Maximum von 20 Punkten wurde von keiner Schülerin und von keinem Schüler erreicht.


3.3 Zusammenhang zwischen freetime und G3

Untersuchen Sie den Zusammenhang zwischen freetime und G3.

Die Variable freetime ist ordinal skaliert und umfasst fünf geordnete Kategorien von „sehr niedrig“ bis „sehr hoch“. Für die folgende Analyse wird sie vereinfachend als quasi-metrisch behandelt. Diese Annahme bedeutet, dass die Abstände zwischen benachbarten Antwortkategorien näherungsweise als vergleichbar interpretiert werden.

Erstellen Sie ein Streudiagramm und berechnen Sie die Pearson-Korrelation. Bestimmen Sie ergänzend die Spearman-Rangkorrelation und beurteilen Sie, ob beide Kennwerte zu einer vergleichbaren inhaltlichen Schlussfolgerung führen. Die Spearman-Rangkorrelation wird ergänzend berechnet, um zu prüfen, ob die inhaltliche Schlussfolgerung auch dann bestehen bleibt, wenn freetime nicht quasi-metrisch, sondern ausschließlich entsprechend seiner ordinalen Rangordnung berücksichtigt wird. Fallen Pearson- und Spearman-Korrelation ähnlich aus, spricht dies dafür, dass der festgestellte Zusammenhang nicht wesentlich von der Annahme gleich großer Abstände zwischen den Kategorien von freetime abhängt.

```
# Streudiagramm mit leicht versetzten Punkten erstellen  
gf_point(G3 ~ jitter(freetime), data = student, alpha = 0.4)
```



```
# Pearson-Korrelation unter quasi-metrischer Annahme berechnen  
cor(G3 ~ freetime, data = student, method = "pearson")
```

```
[1] -0.1227049
```

```
# Spearman-Rangkorrelation als Robustheitsprüfung berechnen  
cor(G3 ~ freetime, data = student, method = "spearman")
```

```
[1] -0.1283748
```

Die Variable `freetime` ist ordinal skaliert, wird für die Pearson-Korrelation hier jedoch vereinfachend als quasi-metrisch behandelt. Damit wird angenommen, dass die Abstände zwischen benachbarten Skalenstufen näherungsweise vergleichbar sind. Diese Annahme folgt nicht automatisch aus der Codierung von 1 bis 5.

Die Pearson-Korrelation zwischen freier Zeit und Abschlussnote beträgt $r = -0,123$. Sie weist auf einen schwachen negativen linearen Zusammenhang hin: Höhere Ausprägungen von `freetime` gehen in der vorliegenden Stichprobe tendenziell mit etwas niedrigeren Abschlussnoten einher.

Spearman's Rangkorrelation beträgt ergänzend $r_s = -0,128$. Da beide Kennwerte nahezu gleich ausfallen, bleibt die inhaltliche Schlussfolgerung unabhängig von der Behandlung der Skala gleich: Der Zusammenhang ist negativ, aber schwach.

Im Streudiagramm ist dieser Zusammenhang nur begrenzt erkennbar; die Abschlussnoten streuen innerhalb der Freizeitstufen deutlich.

4. Inferenzstatistik

4.1 Bootstrap für den Mittelwert von G3

Bestimmen Sie für den Mittelwert von G3 mithilfe des Bootstrap-Verfahrens den Standardfehler und ein 95%-Konfidenzintervall.

```
# beobachteten Mittelwert berechnen
meang3 <- mean(~ G3, data = student)

# Bootstrap-Verteilung erzeugen
set.seed(12345)
bootg3 <- do(1000) * mean(~ G3, data = resample(student))

# erste Fälle anzeigen
head(bootg3)
```

```
      mean
1 11.99076
2 12.01233
3 12.12943
4 12.06780
5 11.81048
6 12.15100
```

```
# Standardfehler bestimmen
sd(~ mean, data = bootg3)
```

```
[1] 0.1246217
```

```
# 95%-Konfidenzintervall bestimmen
qdata(~ mean, p = c(0.025, 0.975), data = bootg3)
```

```
      2.5%      97.5%
11.65636 12.13559
```

Der bootstrap-basierte Standardfehler des Schätzers beträgt 0,124 Punkte. Das 95%-Konfidenzintervall für den mittleren G3-Wert reicht von 11,66 bis 12,14 Punkten. Der Stichprobenmittelwert von 11,91 ist damit

relativ präzise geschätzt; bei wiederholten Stichproben wäre nur mit moderaten Schwankungen des Mittelwerts zu rechnen.


4.2 Histogramm der Bootstrap-Verteilung

Stellen Sie die Bootstrap-Verteilung der Mittelwerte grafisch dar. Markieren Sie den beobachteten Stichprobenmittelwert sowie die untere und obere Grenze des 95%-Konfidenzintervalls. Beschreiben Sie die Form und Streuung der Bootstrap-Verteilung.

```
# 95%-Konfidenzintervall bestimmen
ki_g3 <- as.numeric(
  qdata(~ mean, p = c(0.025, 0.975), data = bootg3)
)

# untere und obere Intervallgrenze explizit speichern
ki_unter <- ki_g3[1]
ki_ober <- ki_g3[2]

# Histogramm der Bootstrap-Verteilung zeichnen
gf_histogram(~ mean, data = bootg3, bins = 20) |>
  gf_vline(
    xintercept = meang3,
    color = "red"
  ) |>
  gf_vline(
    xintercept = ki_unter,
    linetype = "dashed",
    color = "blue"
  ) |>
  gf_vline(
    xintercept = ki_ober,
    linetype = "dashed",
    color = "blue"
  )
```



Die Bootstrap-Verteilung der Mittelwerte ist annähernd symmetrisch um den beobachteten Mittelwert von 11,91 Punkten zentriert. Die rote Linie markiert den beobachteten Stichprobenmittelwert.

Die beiden blauen gestrichelten Linien markieren die untere und die obere Grenze des 95%-Konfidenzintervalls. Diese liegen bei 11,658 beziehungsweise 12,143 Punkten.

Die Grafik zeigt, dass die durch wiederholtes Resampling erzeugten Mittelwerte vergleichsweise eng um den beobachteten Mittelwert streuen. Die annähernd symmetrische Form ist ein Merkmal der hier vorliegenden Bootstrap-Verteilung des Mittelwerts; sie ergibt sich nicht allein durch das Bootstrap-Verfahren, sondern hängt auch von den vorliegenden Daten, dem Schätzer und dem Stichprobenumfang ab.

4.3 Mittelwertvergleich für internet

Untersuchen Sie mithilfe einer linearen Regression, ob sich die mittlere Abschlussnote G3 in der vorliegenden Stichprobe zwischen Schülerinnen und Schülern mit und ohne Internetzugang zu Hause unterscheidet.

Verwenden Sie `internet = no` als Referenzgruppe. Geben Sie den geschätzten Mittelwert der Referenzgruppe sowie die geschätzte Mittelwertdifferenz für `internet = yes` an.

Bestimmen Sie außerdem ein 95%-Konfidenzintervall für die Mittelwertdifferenz und beurteilen Sie anhand des Intervalls und des p-Werts, ob ein mittlerer Unterschied von 0 Punkten mit den Daten vereinbar ist. Formulieren Sie die Nullhypothese und die zweiseitige Alternativhypothese.

```
# internet als nominale Faktorvariable verwenden;
# "no" wird zur eindeutigen Interpretation als Referenz festgelegt
student$internet <- factor(student$internet, levels = c("no", "yes"))

# lineares Modell schätzen
modinternet <- lm(G3 ~ internet, data = student)

# Modellzusammenfassung ausgeben
summary(modinternet)
```

```
Call:
lm(formula = G3 ~ internet, data = student)

Residuals:
    Min       1Q   Median       3Q      Max
-12.1727  -2.0265  -0.1727   1.8273   7.9735

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  11.0265     0.2601  42.39 < 2e-16 ***
internetyes   1.1462     0.2970   3.86 0.000125 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.197 on 647 degrees of freedom
Multiple R-squared:  0.02251,    Adjusted R-squared:  0.021
F-statistic: 14.9 on 1 and 647 DF,  p-value: 0.0001249
```

```
# Koeffizienten ausgeben
coef(modinternet)
```

```
(Intercept) internetyes
 11.026490    1.146201
```

```
# 95%-Konfidenzintervalle der Modellkoeffizienten ausgeben
ki_internet <- confint(modinternet, "internetyes", level = 0.95)
ki_internet
```

```
          2.5 %    97.5 %
internetyes 0.5630735 1.729328
```

Die Nullhypothese lautet:

$$H_0 : \beta_{\text{internetyes}} = 0$$

Unter der Nullhypothese besteht in der Grundgesamtheit kein mittlerer Unterschied in der Abschlussnote G3 zwischen Schülerinnen und Schülern mit Internetzugang und Schülerinnen und Schülern ohne Internetzugang.

Die zweiseitige Alternativhypothese lautet:

$$H_1 : \beta_{\text{internetyes}} \neq 0$$

Nach der Alternativhypothese besteht in der Grundgesamtheit ein mittlerer Unterschied in der Abschlussnote G3 zwischen den beiden Gruppen.

Schülerinnen und Schüler mit Internetzugang erreichen in der vorliegenden Stichprobe im Mittel 12,17 Punkte, Schülerinnen und Schüler ohne Internetzugang im Mittel 11,03 Punkte.

Der Achsenabschnitt (Intercept) beschreibt den geschätzten Mittelwert der Referenzgruppe `internet = no` und beträgt 11,03 Punkte. Der Koeffizient für `internetyes` beträgt 1,146 Punkte. Schülerinnen und Schüler mit Internetzugang erzielen damit in dieser Stichprobe im Mittel eine um rund 1,15 Punkte höhere Abschlussnote als Schülerinnen und Schüler ohne Internetzugang.

Das 95%-Konfidenzintervall für den Mittelwertunterschied reicht von 0,56 bis 1,72 Punkten. Da der Wert 0 nicht im Intervall liegt, ist ein mittlerer Unterschied von 0 Punkten mit den Daten auf dem 5%-Signifikanzniveau nicht vereinbar. Der p-Wert liegt unter 0,001. Die Nullhypothese wird daher verworfen.

Der Befund beschreibt einen Mittelwertunterschied in der vorliegenden Stichprobe. Er erlaubt für sich genommen keine kausale Aussage darüber, ob Internetzugang zu einer höheren Abschlussnote führt.

4.4 Permutationsverteilung für `internet`

Formulieren Sie für den Koeffizienten von `internet` im linearen Regressionsmodell `G3 ~ internet` die Nullhypothese und die Alternativhypothese. Erzeugen Sie anschließend eine Permutationsverteilung für diesen Koeffizienten, bestimmen Sie den p-Wert und treffen Sie eine Entscheidung auf einem Signifikanzniveau von 5%. Gehen Sie davon aus, dass unter der Nullhypothese kein Zusammenhang besteht und die Gruppenzugehörigkeit zufällig ist. Mischen Sie daher die Variable `internet` mehrfach neu, während die Noten gleich bleiben, und berechnen Sie jeweils den Koeffizienten des linearen Modells. Visualisieren Sie die resultierende Permutationsverteilung in einem Histogramm und markieren Sie den beobachteten Koeffizienten, um seine Lage im Vergleich zur Nullverteilung zu beurteilen.

```
set.seed(12345)
perminternet <- do(1000) * lm(G3 ~ shuffle(internet), data = student)

# Spaltennamen prüfen
names(perminternet)
```


```
[1] "Intercept"  "internetyes" "sigma"      "r.squared"  "F"
[6] "numdf"      "dendf"       ".row"       ".index"
```

```
# zweite Spalte umbenennen
names(perminetnet)[2] <- "internetperm"

# beobachteten Koeffizienten speichern
binternet <- coef(modinternet)[2]
binternet
```

```
internetyes
1.146201
```

```
# Histogramm
gf_histogram(~ internetperm, data = perminetnet, bins = 30) |>
  gf_vline(xintercept = binternet, color = "red")
```



```
# p-Wert
mean(abs(perminetnet$internetperm) >= abs(binternet))
```

```
[1] 0
```

```
# Anzahl mindestens so extremer Permutationen
b <- sum(abs(perminetnet$internetperm) >= abs(binternet))

# Monte-Carlo-korrigierter zweiseitiger p-Wert
p_perm <- (b + 1) / (nrow(perminetnet) + 1)

p_perm
```

```
[1] 0.000999001
```

Die Nullhypothese lautet $H_0 : \beta_{\text{internet}} = 0$; es besteht kein Unterschied in der mittleren Abschlussnote zwischen Schülerinnen und Schülern mit und ohne Internetzugang. Die Alternativhypothese lautet $H_1 : \beta_{\text{internet}} \neq 0$; es besteht ein Unterschied.

Der beobachtete Koeffizient beträgt 1,146 Punkte und liegt weit außerhalb der unter der Nullhypothese erwarteten Permutationsverteilung. In keiner der 1.000 zufälligen Permutationen trat ein Koeffizient auf, dessen Betrag mindestens so groß war wie der Betrag des beobachteten Koeffizienten. Der naive simulationsbasierte Anteil beträgt daher 0. Mit der üblichen Monte-Carlo-Korrektur ergibt sich jedoch

$$p = \frac{0 + 1}{1000 + 1} \approx 0,001.$$

Da dieser p-Wert deutlich kleiner als 0,05 ist, wird die Nullhypothese auf dem 5%-Signifikanzniveau verworfen. Es gibt statistische Hinweise auf einen Unterschied in den mittleren Abschlussnoten zwischen Schülerinnen und Schülern mit und ohne Internetzugang.

4.5 Bootstrap für die Korrelation zwischen absences und G3

Bestimmen Sie für die Pearson-Korrelation zwischen der Anzahl der Fehlzeiten absences und der Abschlussnote G3 die beobachtete Korrelation. Schätzen Sie anschließend mithilfe eines Bootstrap-Verfahrens den Standardfehler der Korrelation und bestimmen Sie ein 95%-Konfidenzintervall.

Interpretieren Sie die Richtung und Stärke des Zusammenhangs. Erläutern Sie außerdem, was der Bootstrap-Standardfehler über die Unsicherheit der Korrelationsschätzung aussagt, und beurteilen Sie anhand des Konfidenzintervalls, ob ein fehlender linearer Zusammenhang mit den Daten vereinbar ist.

```
# beobachtete Pearson-Korrelation berechnen
rbeob <- cor(G3 ~ absences, data = student)
rbeob
```

```
[1] -0.09137906
```

```
# Bootstrap-Verteilung der Korrelation erzeugen
set.seed(12345)
bootcor <- do(1000) *
  cor(G3 ~ absences, data = resample(student))

# Bootstrap-Standardfehler bestimmen
se_bootcor <- sd(~ cor, data = bootcor)
se_bootcor
```

```
[1] 0.0411852
```

```
# untere und obere Grenze des 95%-Konfidenzintervalls bestimmen
ki_cor <- as.numeric(
  qdata(~ cor, p = c(0.025, 0.975), data = bootcor)
)

ki_unter <- ki_cor[1]
ki_ober <- ki_cor[2]

ki_unter
```

```
[1] -0.1790813
```

```
ki_ober
```

```
[1] -0.01349565
```

Die beobachtete Pearson-Korrelation zwischen Fehlzeiten und Abschlussnote beträgt $r = -0,091$. Sie ist negativ: Schülerinnen und Schüler mit mehr Fehlzeiten erreichen in der vorliegenden Stichprobe tendenziell niedrigere Abschlussnoten.

Der Bootstrap-Standardfehler der Korrelation beträgt 0,041. Er beschreibt die geschätzte typische Streuung der Korrelationsschätzung über gedachte wiederholte Stichproben derselben Größe. Ein Standardfehler von 0,041 bedeutet hier, dass die geschätzte Korrelation von Stichprobe zu Stichprobe typischerweise um ungefähr 0,04 Korrelationspunkte schwanken würde. Das 95%-Konfidenzintervall reicht von $-0,179$ bis $-0,013$. Da der Wert 0 nicht im Intervall liegt, ist ein fehlender linearer Zusammenhang zwischen Fehlzeiten und Abschlussnote mit den vorliegenden Daten auf dem 5%-Signifikanzniveau nicht vereinbar.


Der Zusammenhang ist jedoch sehr schwach ausgeprägt. Fehlzeiten stehen in diesen Daten zwar in einem statistisch von 0 unterscheidbaren negativen linearen Zusammenhang mit der Abschlussnote, erklären für sich genommen aber nur einen sehr kleinen Teil der Unterschiede in den Abschlussnoten.

Die Pearson-Korrelation beschreibt ausschließlich einen linearen Zusammenhang. Da absences eine Zählvariable ist und einzelne hohe Fehlzeitenwerte den Zusammenhang beeinflussen können, sollte ergänzend ein Streudiagramm betrachtet werden. Aus dem Zusammenhang kann keine kausale Wirkung von Fehlzeiten auf die Abschlussnote abgeleitet werden.

4.6 Histogramm der Bootstrap-Korrelationen

Stellen Sie die Bootstrap-Verteilung der Pearson-Korrelationen zwischen der Anzahl der Fehlzeiten absences und der Abschlussnote G3 grafisch dar. Markieren Sie die beobachtete Korrelation sowie die untere und obere Grenze des 95%-Konfidenzintervalls.

```
# Histogramm der Bootstrap-Korrelationen zeichnen
gf_histogram(~ cor, data = bootcor, bins = 20) |>
  gf_vline(
    xintercept = rbeob,
    color = "red"
  ) |>
  gf_vline(
    xintercept = ki_unter,
    linetype = "dashed",
    color = "blue"
  ) |>
  gf_vline(
    xintercept = ki_ober,
    linetype = "dashed",
    color = "blue"
  )
```



Die Bootstrap-Verteilung der Pearson-Korrelationen ist um die beobachtete Korrelation von $r = -0,091$ zentriert. Die rote Linie markiert diese beobachtete Korrelation.

Die beiden blauen gestrichelten Linien markieren die untere und obere Grenze des 95%-Konfidenzintervalls. Diese liegen bei $-0,179$ beziehungsweise $-0,013$.

Die Nullkorrelation von $r = 0$ liegt nicht im Konfidenzintervall. Ein fehlender linearer Zusammenhang zwischen Fehlzeiten und Abschlussnote ist mit den vorliegenden Daten auf dem 5%-Signifikanzniveau daher nicht vereinbar.

Die Bootstrap-Korrelationen liegen insgesamt im negativen Bereich, ihre Beträge bleiben jedoch gering. Der Zusammenhang ist damit statistisch von 0 unterscheidbar, inhaltlich aber nur schwach ausgeprägt.

5. Bayes-Statistik

5.1 Binäre Variable pass erzeugen

Erzeugen Sie aus G3 die binäre Variable pass, wobei $G3 \geq 10$ als bestanden gilt. Lassen Sie sich anschließend die absoluten und relativen Häufigkeiten ausgeben und bestimmen Sie den Erfolgsanteil. Formulieren Sie im Text, wie viele Schülerinnen und Schüler bestanden haben und welcher Anteil der Stichprobe dies ist.

```
# Binäre Variable pass erzeugen
student <- student |> mutate(pass = case_when(G3 >=10 ~ "yes", G3 < 10 ~ "no"))

# Absolute Häufigkeiten ausgeben
tally(~ pass, data = student)
```

```
pass
no yes
100 549
```

```
# Relative Häufigkeiten ausgeben
tally(~ pass, data = student, format = "proportion")
```

```
pass
      no      yes
0.1540832 0.8459168
```

```
# Erfolgsanteil bestimmen
n <- nrow(student)
y <- count( ~ pass == "yes", data = student)
erfolgsanteil <- y / n
erfolgsanteil
```

```
n_TRUE
0.8459168
```

Nach der Dichotomisierung haben 549 von 649 Schülerinnen und Schülern bestanden; das entspricht 84,59 Prozent. Nicht bestanden haben 100 Personen beziehungsweise 15,41 Prozent. Der beobachtete Anteil der Bestandenen in der Stichprobe liegt bei 84,59%.

5.2 Informative Priori-Verteilung darstellen

Die portugiesische Statistikbehörde berichtet für aktuelle Abschlussprüfungen eine Bestehensquote von ungefähr 91,2% (vgl. Kennzahlenseite des INE¹). Für die Fallstudie soll dieser externe Wert leicht gerundet als Vorannahme verwendet werden.

Legen Sie für den Erfolgsanteil der bestandenen Schülerinnen und Schüler eine informative Beta-Priori-Verteilung fest, deren Erwartungswert bei 0,90 bei insgesamt 20 Pseudo-Beobachtungen liegt, und stellen Sie diese grafisch dar. Begründen Sie kurz, wie sich die gewählte Priori-Verteilung an der externen Bestehensquote orientiert.


```
# Werte für pi bereitstellen
ppi <- seq(from = 0, to = 1, by = 1/1000)

# informative Priori-Verteilung mit Erwartungswert ca. 0,90 festlegen
a_prior <- 18
b_prior <- 2

# Dichtevektor der Priori-Verteilung
dppi_prior <- dbeta(ppi, shape1 = a_prior, shape2 = b_prior)

# zeichnen
gf_line(dppi_prior ~ ppi) |>
  gf_labs(
    x = expression(pi),
    y = expression(f(pi)),
    title = paste0("Beta(", a_prior, ", ", b_prior, ")")
  )
```

¹Instituto Nacional de Estatística (INE), Kennzahlenseite zur Bestehensquote: https://www.ine.pt/xportal/xmain?xpid=INE&xpgid=ine_indicadores&indOcorrCod=0012635&contexto=bd&selTab=tab2



Die informative Priori-Verteilung Beta(18, 2) legt vor der Datensicht bereits hohe Erfolgswahrscheinlichkeiten nahe. Ihr Erwartungswert liegt bei 0,90 und orientiert sich damit an der extern berichteten Bestehensquote von rund 91,2 % für Abschlussprüfungen in Portugal, die hier aus Gründen der Einfachheit leicht gerundet wird.

Die Priori-Verteilung entspricht 20 Pseudo-Beobachtungen (18 „Erfolge“ und 2 „Misserfolge“) und spiegelt die Vorannahme wider, dass typischerweise ein sehr großer Teil einer Lerngruppe besteht. Gleichzeitig trifft dieser Prior in der Fallstudie auf eine recht große reale Stichprobe, sodass die beobachteten Daten die Posteriori-Verteilung deutlich prägen werden.

5.3 Likelihood-Funktion darstellen

Stellen Sie die Likelihood-Funktion für den Erfolgsanteil π auf Basis der beobachteten Daten zu `pass` dar und bestimmen Sie den Maximum-Likelihood-Schätzer. Stellen Sie die Likelihood-Funktion zusätzlich als Grafik dar und markieren Sie den Maximum-Likelihood-Schätzer grafisch.

```
# n und y aus der erzeugten Variable pass bestimmen
n <- nrow(student)
y <- count(~ pass == "yes", data = student)

n
```

```
[1] 649
```

```
y
```

```
n_TRUE
549
```

```
# Werte für pi bereitstellen (wie in 5.2)
ppi <- seq(from = 0, to = 1, by = 1/1000)


# Likelihood berechnen
```

```
lppi <- dbinom(y, size = n, prob = ppi)

# Maximum-Likelihood-Schätzer
mle <- y / n
mle
```

```
n_TRUE
0.8459168
```

```
# zeichnen mit gestrichelter Linie beim MLE
gf_line(lppi ~ ppi) |>
  gf_labs(
    x      = expression(pi),
    y      = "Likelihood",
    title  = "Likelihood-Funktion"
  ) |>
  gf_vline(
    xintercept = mle,
    color      = "red",
    linetype   = "dashed"
  )
```



Die Likelihood-Funktion beschreibt, wie stark unterschiedliche Werte des Erfolgsanteils π durch die beobachteten Daten relativ unterstützt werden. Sie basiert auf der Binomialverteilung $Y \sim \text{Binom}(n, \pi)$ und wird für alle $\pi \in [0, 1]$ ausgewertet.

In der vorliegenden Stichprobe gelten 549 von 649 Schülerinnen und Schülern als bestanden. Der Maximum-Likelihood-Schätzer ergibt sich als

$$\hat{\pi} = \frac{y}{n} = \frac{549}{649} \approx 0,846$$

und entspricht damit direkt dem beobachteten Erfolgsanteil in der Stichprobe.

Die rote gestrichelte Linie im Plot markiert diesen Wert, an dem die Likelihood ihr Maximum erreicht.


5.4 Posteriori-Verteilung bestimmen

Bestimmen Sie auf Basis der Daten die Posteriori-Verteilung sowie den Posterior-Modus und ein 95%-Kreditabilitätsintervall.

```
# alpha_post und beta_post berechnen
a_post <- a_prior + y
b_post <- b_prior + (n - y)

# Dichtevektor
dppi <- dbeta(ppi, shape1 = a_post, shape2 = b_post)

# zeichnen
gf_line(dppi ~ ppi) |>
  gf_labs(x = expression(pi), y = expression(f(pi)),
    title = paste0("Beta(", a_post, ", ", b_post, ")"))
```



```
# Modus (Punktschätzer)
modus <- (a_post - 1) / (a_post + b_post - 2)
modus
```

```
n_TRUE
0.8485757
```

```
# 95%-Kreditabilitätsintervall
kred95 <- qbeta(c(0.025, 0.975), a_post, b_post)

kred_unter <- kred95[1]
kred_ober <- kred95[2]


kred_unter
```

```
[1] 0.8193525
```

```
kred_ober
```

```
[1] 0.8737473
```

```
# zeichnen mit Modus und Intervallgrenzen
gf_line(dppi ~ ppi) |>
  gf_labs(
    x      = expression(pi),
    y      = expression(f(pi)),
    title  = paste0("Beta(", a_post, ", ", b_post, ")")
  ) |>
  gf_vline(
    xintercept = modus,
    color      = "blue"
  ) |>
  gf_vline(
    xintercept = kred_unter,
    color      = "green",
    linetype   = "dashed"
  ) |>
  gf_vline(
    xintercept = kred_ober,
    color      = "green",
    linetype   = "dashed"
  )
```



Unter Einbezug der Daten ergibt sich die Posteriori-Verteilung Beta(567, 102). Der Posterior-Modus beträgt 0,848 und das 95%-Kreditabilitätsintervall reicht von 0,819 bis 0,874.

Bayesianisch betrachtet liegt der Erfolgsanteil damit sehr wahrscheinlich im Bereich von rund 81,9 % bis 87,4 %. Die Posterior-Masse konzentriert sich klar im oberen Bereich zwischen 0,8 und 0,9; ein Erfolgsanteil deutlich darunter erhält mit den vorliegenden Daten nur geringe Plausibilität.

5.5 Priorvergleich durchführen

Vergleichen Sie die Auswirkungen der informativen Prior-Verteilung $\text{Beta}(18, 2)$ mit einer uniformen Prior $\text{Beta}(1, 1)$, indem Sie beide Posteriori-Verteilungen grafisch darstellen. Beschreiben Sie, ob und wie sich die Posteriori-Verteilungen voneinander unterscheiden und welche Rolle die große Stichprobe für die Bedeutung der Priorwahl spielt.

```
# ppi
ppi <- seq(from = 0, to = 1, by = 1/1000)

# informative Prior-Verteilung Beta(18, 2) (Erwartungswert 0,90, 20 Pseudo-
# Beobachtungen)
a_prior <- 18
b_prior <- 2

# Posteriorparameter für die informative Prior
a_post <- a_prior + y
b_post <- b_prior + (n - y)


# Dichtevektor der Posteriori-Verteilung unter der informativen Prior
dppi <- dbeta(ppi, shape1 = a_post, shape2 = b_post)

# uniforme bzw. schwach informative Prior Beta(1, 1)
a_prior2 <- 1
b_prior2 <- 1

# Posteriorparameter für die uniforme Prior
a_post2 <- a_prior2 + y
b_post2 <- b_prior2 + (n - y)

# Dichtevektor der Posteriori-Verteilung unter der uniformen Prior
dppi2 <- dbeta(ppi, shape1 = a_post2, shape2 = b_post2)

# beide Posteriorverteilungen zeichnen
gf_line(dppi ~ ppi, color = "red") |>
gf_line(dppi2 ~ ppi, color = "blue") |>
gf_labs(x = expression(pi), y = expression(f(pi)),
        title = "Posteriorvergleich")
```



Unter der informativen Prior-Verteilung $\text{Beta}(18, 2)$ ergibt sich die Posteriori-Verteilung $\text{Beta}(567, 102)$. Unter der uniformen Prior $\text{Beta}(1, 1)$ ergibt sich die Posteriori-Verteilung $\text{Beta}(550, 101)$.

Die beiden Posteriori-Verteilungen unterscheiden sich nur geringfügig, wie sich am sehr ähnlichen Kurvenverlauf ablesen lässt. Das zeigt, dass die Daten mit 649 Beobachtungen deutlich informativer sind als die gewählte Vorannahme: Selbst eine relativ stark auf hohe Erfolgsanteile konzentrierte Prior-Verteilung führt hier nicht zu einem inhaltlich anderen Ergebnis als eine uniforme bzw. schwach informative Prior.

Inhaltlich ist der geschätzte Erfolgsanteil damit robust gegenüber einer plausiblen Variation der Priorwahl.

6. Lineare Regression

6.1 Einfache lineare Regression

Untersuchen Sie, ob ein linearer Zusammenhang zwischen der Anzahl der Fehlzeiten `absences` und der Abschlussnote `G3` besteht.

Formulieren Sie zunächst eine Forschungsfrage sowie eine Null- und eine zweiseitige Alternativhypothese. Schätzen Sie das lineare Regressionsmodell $G3 \sim \text{absences}$ und interpretieren Sie die wichtigsten Ergebnisse.

Beurteilen Sie anhand des p-Werts, ob der Regressionskoeffizient von `absences` statistisch von 0 unterscheidbar ist. Geben Sie außerdem das Bestimmtheitsmaß an und nehmen Sie eine Punktprognose für eine Schülerin bzw. einen Schüler vor, die bzw. der 5 Fehlzeiten aufweist.

```
# einfaches lineares Regressionsmodell schätzen
mod1 <- lm(G3 ~ absences, data = student)

# Modellzusammenfassung ausgeben
summary(mod1)
```

```
Call:
lm(formula = G3 ~ absences, data = student)

Residuals:
    Min       1Q   Median       3Q      Max
-12.1388  -1.8207  -0.1388   1.9884   7.1157
```

```

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept) 12.13880    0.16099  75.399  <2e-16 ***
absences    -0.06361    0.02725  -2.334   0.0199 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.22 on 647 degrees of freedom
Multiple R-squared:  0.00835,    Adjusted R-squared:  0.006817
F-statistic: 5.448 on 1 and 647 DF,  p-value: 0.0199

```

```

# Koeffizienten ausgeben
coef(mod1)

```

```

(Intercept)    absences
12.13880086 -0.06361337

```

```

# Bestimmtheitsmaß ausgeben
rsquared(mod1)

```

```

[1] 0.008350132

```

```

# Punktprognose für absences = 5 berechnen
predict(mod1, newdata = data.frame(absences = 5))

```

```

      1
11.82073

```

Die Forschungsfrage lautet: Besteht ein linearer Zusammenhang zwischen der Anzahl der Fehlzeiten und der Abschlussnote im Portugiesisch-Kurs?

Die Nullhypothese lautet:

$$H_0 : \beta_{\text{absences}} = 0$$

Danach besteht kein linearer Zusammenhang zwischen der Anzahl der Fehlzeiten und der Abschlussnote.

Die zweiseitige Alternativhypothese lautet:

$$H_1 : \beta_{\text{absences}} \neq 0$$

Danach besteht ein linearer Zusammenhang zwischen der Anzahl der Fehlzeiten und der Abschlussnote.

Der Achsenabschnitt beträgt 12,139 Punkte. Er beschreibt die geschätzte mittlere Abschlussnote für Schülerinnen und Schüler mit 0 Fehlzeiten.

Der Koeffizient für absences beträgt -0,064. Eine zusätzliche Fehlzeit geht im Modell im Mittel mit einer um rund 0,064 Punkte niedrigeren erwarteten Abschlussnote einher. Der Zusammenhang ist damit negativ, aber sehr schwach. Der p-Wert für den Koeffizienten von absences beträgt 0,020. Der Koeffizient ist damit auf dem 5%-Signifikanzniveau statistisch von 0 unterscheidbar. Die Nullhypothese wird verworfen. Das Bestimmtheitsmaß beträgt $R^2 = 0,008$. Die Anzahl der Fehlzeiten erklärt damit lediglich rund 0,8 % der Unterschiede in den Abschlussnoten. Der statistisch erkennbare Zusammenhang ist inhaltlich daher klein.

Für eine Person mit 5 Fehlzeiten ergibt sich eine Punktprognose von 11,821 Punkten:

$$\widehat{G3} = 12,139 - 0,064 \cdot 5 = 11,821$$

Die Punktprognose beschreibt den vom Modell geschätzten mittleren Wert. Die tatsächliche Abschlussnote einer einzelnen Person kann davon deutlich abweichen. Der Zusammenhang erlaubt zudem keine kausale Aussage darüber, ob Fehlzeiten selbst zu niedrigeren Abschlussnoten führen.

6.2 Multiple linear Regression

Untersuchen Sie, ob die Anzahl der Fehlzeiten `absences`, die freie Zeit nach der Schule `freetime` und der Internetzugang zu Hause `internet` gemeinsam mit der Abschlussnote `G3` zusammenhängen.

Formulieren Sie zunächst eine Forschungsfrage sowie eine Null- und eine Alternativhypothese für das Gesamtmodell. Schätzen Sie das multiple lineare Regressionsmodell $G3 \sim \text{absences} + \text{freetime} + \text{internet}$.

Interpretieren Sie den Achsenabschnitt und alle Regressionskoeffizienten unter Konstanthaltung der jeweils übrigen Variablen. Beurteilen Sie anhand der p-Werte, ob die einzelnen Koeffizienten statistisch von 0 unterscheidbar sind. Berichten und interpretieren Sie außerdem das Bestimmtheitsmaß.

Die Variable `freetime` ist ordinal skaliert und umfasst ursprünglich die Werte 1 bis 5. Kodieren Sie `freetime` für die Regression so um, dass 0 der niedrigsten Ausprägung entspricht. Für das Modell wird `freetime` vereinfachend als quasi-metrische Variable behandelt. Machen Sie deutlich, welche Annahme damit verbunden ist.

```
# freetime umkodieren, so dass 0 der niedrigsten Stufe entspricht
student$freetime <- student$freetime - 1

# Referenzgruppe für internet festlegen
student$internet <- factor(student$internet, levels = c("no", "yes"))

# multiples lineares Regressionsmodell schätzen
mod2 <- lm(G3 ~ absences + freetime + internet, data = student)

# Modellzusammenfassung ausgeben
summary(mod2)
```

Call:

```
lm(formula = G3 ~ absences + freetime + internet, data = student)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-12.9584	-1.6658	-0.1042	1.9192	7.6996

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	12.10824	0.36457	33.213	< 2e-16 ***
absences	-0.07313	0.02677	-2.732	0.00647 **
freetime	-0.41540	0.11816	-3.516	0.00047 ***
internetyes	1.26555	0.29433	4.300	1.97e-05 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.154 on 645 degrees of freedom

Multiple R-squared: 0.05103, Adjusted R-squared: 0.04662

F-statistic: 11.56 on 3 and 645 DF, p-value: 2.17e-07

```
# Koeffizienten ausgeben  
coef(mod2)
```

```
(Intercept)    absences    freetime internetyes  
12.1082414   -0.0731350   -0.4154032    1.2655473
```

```
# Bestimmtheitsmaß ausgeben  
rsquared(mod2)
```

```
[1] 0.05103472
```

Die Forschungsfrage lautet: Hängen Fehlzeiten, freie Zeit nach der Schule und Internetzugang zu Hause unter gemeinsamer Berücksichtigung mit der Abschlussnote im Portugiesisch-Kurs zusammen?

Für das Gesamtmodell lautet die Nullhypothese:

$$H_0 : \beta_{\text{absences}} = \beta_{\text{freetime}} = \beta_{\text{internetyes}} = 0$$

Danach besteht unter Berücksichtigung der übrigen Variablen kein linearer Zusammenhang zwischen den Prädiktoren und der Abschlussnote.

Die Alternativhypothese lautet:

$$H_1 : \text{Mindestens einer der Regressionskoeffizienten ist nicht gleich } 0.$$

Der Achsenabschnitt beträgt 12,524 Punkte. Er beschreibt die geschätzte Abschlussnote für Schülerinnen und Schüler ohne Internetzugang, mit 0 Fehlzeiten und der Ausprägung 0 bei freetime.

Unter Konstanzhaltung von freetime und internet geht eine zusätzliche Fehlzeit mit einer um durchschnittlich 0,073 Punkte niedrigeren erwarteten Abschlussnote einher. Der Koeffizient von absences ist mit $p = 0,006$ statistisch von 0 unterscheidbar. Die Nullhypothese eines fehlenden linearen Zusammenhangs zwischen Fehlzeiten und Abschlussnote wird daher verworfen.

Unter Konstanzhaltung von absences und internet geht eine um eine Stufe höhere Ausprägung von freetime mit einer um durchschnittlich 0,415 Punkte niedrigeren erwarteten Abschlussnote einher. Der Koeffizient ist mit $p < 0,001$ statistisch von 0 unterscheidbar. Diese Interpretation setzt voraus, dass die Abstände zwischen den ordinalen Antwortkategorien von freetime näherungsweise gleich groß sind. Diese quasi-metrische Annahme sollte daher bei der Interpretation berücksichtigt werden.

Unter Konstanzhaltung von Fehlzeiten und freier Zeit erzielen Schülerinnen und Schüler mit Internetzugang im Mittel 1,266 Punkte mehr als Schülerinnen und Schüler ohne Internetzugang. Der Koeffizient für internetyes ist mit $p < 0,001$ statistisch von 0 unterscheidbar. Die Nullhypothese eines durchschnittlichen Unterschieds von 0 Punkten zwischen den Gruppen wird daher verworfen.

Das Bestimmtheitsmaß beträgt $R^2 = 0,051$. Die drei Prädiktoren erklären damit gemeinsam rund 5,1 % der Unterschiede in den Abschlussnoten. Der erklärte Varianzanteil ist damit eher gering.

Die Ergebnisse beschreiben bedingte Zusammenhänge in der vorliegenden Stichprobe. Aus ihnen folgt keine kausale Aussage über die Wirkung von Fehlzeiten, freier Zeit oder Internetzugang auf die Abschlussnote.

6.3 Interaktionsmodell

Untersuchen Sie, ob sich der lineare Zusammenhang zwischen der Anzahl der Fehlzeiten absences und der Abschlussnote G3 je nach Ausprägung der freien Zeit nach der Schule freetime unterscheidet.

Formulieren Sie eine Forschungsfrage sowie eine Null- und eine Alternativhypothese für den Interaktionsterm zwischen absences und freetime.

Schätzen Sie das Interaktionsmodell und interpretieren Sie den Achsenabschnitt und alle Regressionskoeffizienten, insbesondere den Interaktionsterm `absences : freetime`. Begründen Sie Ihre Aussage zur Bedeutung der Interaktion sowohl anhand des p-Werts des Interaktionsterms als auch anhand des Bestimmtheitsmaßes.

```
# Interaktionsmodell schätzen
mod3 <- lm(G3 ~ absences + freetime + internet + absences * freetime,
           data = student)

# Modellzusammenfassung ausgeben
summary(mod3)
```

```
Call:
lm(formula = G3 ~ absences + freetime + internet + absences *
    freetime, data = student)

Residuals:
    Min       1Q   Median       3Q      Max
-12.9765  -1.6493  -0.1162   1.9537   7.7131

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  12.139405   0.420258  28.886 < 2e-16 ***
absences     -0.081688   0.063201  -1.292  0.19665
freetime     -0.430125   0.153924  -2.794  0.00535 **
internetyes   1.267199   0.294764   4.299 1.98e-05 ***
absences:freetime 0.003926  0.026275   0.149  0.88128
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.157 on 644 degrees of freedom
Multiple R-squared:  0.05107,    Adjusted R-squared:  0.04517
F-statistic: 8.664 on 4 and 644 DF,  p-value: 8.155e-07
```

```
# Koeffizienten ausgeben
coef(mod3)
```

```
(Intercept)      absences      freetime  internetyes
12.139404758    -0.081687541    -0.430124931    1.267199457
absences:freetime
0.003925702
```

```
# Bestimmtheitsmaß ausgeben
rsquared(mod3)
```

```
[1] 0.05106761
```

Die Forschungsfrage lautet: Unterscheidet sich der lineare Zusammenhang zwischen Fehlzeiten und Abschlussnote je nach Ausprägung der freien Zeit nach der Schule?

Für den Interaktionsterm lautet die Nullhypothese:

$$H_0 : \beta_{\text{absences:freetime}} = 0,$$

also kein Unterschied im linearen Zusammenhang zwischen absences und G3 über die Stufen von freetime. Die Alternativhypothese lautet:

$$H_1 : \beta_{\text{absences:freetime}} \neq 0.$$

Der Achsenabschnitt von 12,570 Punkten beschreibt die geschätzte Abschlussnote für Schülerinnen und Schüler mit 0 Fehlzeiten, minimaler freier Zeit (freetime = 0, falls entsprechend umkodiert) und ohne Internetzugang (internet = no).

Der Koeffizient für absences beträgt $-0,086$ mit einem p-Wert von $p = 0,329$. Unter Konstanthaltung von freetime und internet geht eine zusätzliche Fehlzeit im Modell im Mittel zwar mit einer etwas niedrigeren erwarteten Abschlussnote einher, dieser Effekt ist jedoch statistisch nicht von 0 unterscheidbar. Die Nullhypothese eines fehlenden linearen Zusammenhangs zwischen Fehlzeiten und Abschlussnote wird für den Haupteffekt beibehalten.

Der Koeffizient für freetime beträgt $-0,430$ mit $p = 0,005$. Unter Konstanthaltung von absences und internet geht eine zusätzliche Stufe auf der freetime-Skala im Modell mit einer im Mittel um rund 0,43 Punkte niedrigeren Abschlussnote einher. Dieser negative Zusammenhang ist statistisch von 0 unterscheidbar.

Der Koeffizient für internetyes beträgt $1,267$ mit $p < 0,001$. Bei minimaler freier Zeit und gegebenen Fehlzeiten beschreibt er den Unterschied im Achsenabschnitt zwischen Schülerinnen und Schülern mit und ohne Internetzugang: Lernende mit Internetzugang haben hier im Mittel eine um etwa 1,27 Punkte höhere erwartete Abschlussnote. Dieser Unterschied ist statistisch von 0 unterscheidbar.

Der Interaktionsterm absences:freetime beträgt $0,004$ mit einem p-Wert von $p = 0,881$. Der p-Wert liegt weit über 0,05; der Interaktionsterm ist statistisch nicht von 0 unterscheidbar. Die Nullhypothese $H_0 : \beta_{\text{absences:freetime}} = 0$ wird auf dem 5%-Signifikanzniveau beibehalten. Es gibt anhand dieses Modells keine statistisch belastbaren Hinweise darauf, dass sich der lineare Zusammenhang zwischen Fehlzeiten und Abschlussnote je nach Ausprägung der freien Zeit unterscheidet.

Das Bestimmtheitsmaß des Interaktionsmodells beträgt $R^2 = 0,051$, das adjustierte $R^2 = 0,045$. Im Vergleich zum Modell ohne Interaktion erhöht sich R^2 praktisch nicht.

Insgesamt zeigt das Interaktionsmodell: Freie Zeit und Internetzugang stehen in einem schwach negativen bzw. positiven Zusammenhang mit der Abschlussnote, Fehlzeiten zeigen in diesem Modell keinen statistisch abgesicherten Haupteffekt. Der Interaktionsterm absences:freetime ist statistisch nicht von 0 unterscheidbar; zudem ist die geschätzte Interaktion mit $0,004$ Punkten pro Einheit sehr klein. Der lineare Zusammenhang zwischen Fehlzeiten und Abschlussnote scheint sich damit nicht erkennbar nach der Ausprägung der freien Zeit zu unterscheiden.

7. Kausale Modellierung

7.1 Naives Modell für paid

Schätzen Sie ein bivariates Modell für den Zusammenhang zwischen paid, also bezahlter Nachhilfe, und der Abschlussnote G3. Erstellen Sie zuvor ein DAG, das diesen Zusammenhang beschreibt. Das zugehörige DAG kann auf der Website DAGitty.net grafisch erstellt werden.

```
# Referenzkategorie festlegen
student$paid <- factor(student$paid, levels = c("no", "yes"))

# Naives Modell schätzen
modpaid1 <- lm(G3 ~ paid, data = student)

# Modellzusammenfassung ausgeben
summary(modpaid1)
```

```
Call:
lm(formula = G3 ~ paid, data = student)

Residuals:
    Min       1Q   Median       3Q      Max
-11.9508  -1.9508   0.0492   2.0492   7.0492

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  11.9508     0.1307   91.431  <2e-16 ***
paidyes      -0.7457     0.5332   -1.399    0.162
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.228 on 647 degrees of freedom
Multiple R-squared:  0.003014, Adjusted R-squared:  0.001473
F-statistic: 1.956 on 1 and 647 DF, p-value: 0.1624
```

```
# Koeffizienten ausgeben
coef(modpaid1)
```

```
(Intercept)    paidyes
 11.9508197   -0.7456915
```

Den folgenden Code können Sie in den DAGitty-Editor einfügen:

```
dag {
  bb="-5.124,-9.299,4.964,10.134"
  G3 [outcome,pos="1.478,-0.493"]
  paid [exposure,pos="-0.787,-0.455"]
  paid -> G3
}
```

Im naiven bivariaten Modell beträgt der Koeffizient für paidyes ungefähr $-0,75$ Punkte. Schülerinnen und Schüler mit bezahltem Zusatzunterricht erzielen damit in diesen Daten im Mittel etwa 0,75 Punkte weniger als die Referenzgruppe ohne bezahlten Zusatzunterricht. Der Intercept beschreibt den geschätzten Mittelwert der Gruppe ohne bezahlte Nachhilfe (paid = no).

Dieses Ergebnis ist rein deskriptiv und erlaubt keine kausale Aussage über die Wirkung von bezahlter Nachhilfe auf die Abschlussnote. Mögliche Drittvariablen wie Lernzeit, frühere Leistungen oder Bildungsaspiration werden im naiven Modell vollständig ausgeblendet. Zudem ist der Koeffizient in diesem Modell statistisch nicht von 0 unterscheidbar.

7.2 Adjustiertes Modell für paid

Schätzen Sie ein adjustiertes Modell für den Zusammenhang zwischen bezahlter Nachhilfe paid und der Abschlussnote G3, in dem Sie zusätzlich freetime, absences, failures und higher berücksichtigen. Erstellen Sie zuvor ein DAG mit den angenommenen theoretischen Zusammenhängen.

Formulieren Sie eine Forschungsfrage sowie eine Null- und eine Alternativhypothese für den Koeffizienten von paidyes. Stellen Sie die Regressionsgleichung des adjustierten Modells explizit auf.

Interpretieren Sie den Achsenabschnitt und die Regressionskoeffizienten für paidyes, freetime, absences, failures und higheryes jeweils als erwartete Änderung von G3 bei einer Änderung der jeweiligen Variablen,

unter Konstanthaltung der übrigen. Beurteilen Sie anhand der p-Werte, ob die einzelnen Koeffizienten statistisch von 0 unterscheidbar sind, und berichten Sie das Bestimmtheitsmaß für das Gesamtmodell.

Hinweis: Das Modell liefert einen adjustierten assoziativen Zusammenhang unter den Annahmen des DAG. Es erlaubt ohne zusätzliche Voraussetzungen keine eindeutige kausale Aussage über die Wirkung von bezahlter Nachhilfe.

```
# Referenzkategorie für higher festlegen
student$higher <- factor(student$higher, levels = c("no", "yes"))

# Adjustiertes Modell schätzen
modpaid2 <- lm(G3 ~ paid + freetime + absences + failures + higher,
               data = student)

# Modellzusammenfassung ausgeben
summary(modpaid2)
```

```
Call:
lm(formula = G3 ~ paid + freetime + absences + failures + higher,
    data = student)

Residuals:
    Min       1Q   Median       3Q      Max
-12.8839  -1.6366   0.0824   1.6851   6.1906

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  10.71644    0.47741  22.447  < 2e-16 ***
paidyes      -0.58745    0.47888  -1.227   0.2204
freetime     -0.21004    0.10891  -1.929   0.0542 .
absences     -0.01862    0.02474  -0.752   0.4520
failures     -1.68462    0.20300  -8.299 6.20e-16 ***
higheryes     2.37750    0.38925   6.108 1.75e-09 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.882 on 643 degrees of freedom
Multiple R-squared:  0.2103,    Adjusted R-squared:  0.2041
F-statistic: 34.24 on 5 and 643 DF,  p-value: < 2.2e-16
```

```
# Koeffizienten ausgeben
coef(modpaid2)
```

```
(Intercept)      paidyes      freetime      absences      failures      higheryes
10.71644355 -0.58744898 -0.21004144 -0.01861845 -1.68462404 2.37750337
```

Den folgenden Code können Sie in den DAGitty-Editor einfügen:

```
dag {
  bb="-3.324,-3.601,3.254,3.573"
  G3 [outcome,pos="0.322,-0.469"]
  absences [adjusted,pos="-2.776,1.232"]
  failures [adjusted,pos="2.706,-1.255"]
}
```

```

higher [adjusted,pos="0.385,-3.003"]
paid [exposure,pos="-0.879,-0.453"]
freetime [adjusted,pos="-2.572,-1.651"]

absences -> G3
absences -> paid
failures -> G3
failures -> paid
higher -> G3
higher -> paid
paid -> G3
freetime -> G3
freetime -> paid
}

```

Die Forschungsfrage lautet: Besteht unter Berücksichtigung von freier Zeit, Fehlzeiten, bisherigen Misserfolgen und Bildungsaspiration ein linearer Zusammenhang zwischen bezahlter Nachhilfe und der Abschlussnote im Portugiesisch-Kurs?

Für den Koeffizienten von `paidyes` lautet die Nullhypothese:

$$H_0 : \beta_{\text{paidyes}} = 0,$$

also kein adjustierter linearer Unterschied in der Abschlussnote zwischen Schülerinnen und Schülern mit und ohne bezahlte Nachhilfe. Die Alternativhypothese lautet:

$$H_1 : \beta_{\text{paidyes}} \neq 0.$$

Der Achsenabschnitt von 10,926 Punkten beschreibt die geschätzte Abschlussnote für Schülerinnen und Schüler ohne bezahlte Nachhilfe (`paid = no`), mit minimaler freier Zeit, 0 Fehlzeiten, keinen bisherigen Misserfolgen und ohne höhere Bildungsaspiration (`higher = no`).

Der Koeffizient für `paidyes` beträgt $-0,587$ mit einem p -Wert von $p = 0,220$. Unter Konstanthaltung von `freetime`, `absences`, `failures` und `higher` erzielen Schülerinnen und Schüler mit bezahlter Nachhilfe in diesem Modell im Mittel etwa 0,59 Punkte weniger als Schülerinnen und Schüler ohne bezahlte Nachhilfe. Da der p -Wert deutlich größer als 0,05 ist, ist dieser Unterschied statistisch nicht von 0 unterscheidbar. Die Nullhypothese $H_0 : \beta_{\text{paidyes}} = 0$ wird auf dem 5%-Signifikanzniveau beibehalten. Das Modell liefert damit keinen statistisch abgesicherten Hinweis auf einen adjustierten linearen Unterschied in der Abschlussnote zwischen den beiden Gruppen.

Der Koeffizient für `freetime` beträgt $-0,210$ bei $p = 0,054$. Eine zusätzliche Stufe auf der `freetime`-Skala geht im Mittel mit einer um rund 0,21 Punkte niedrigeren erwarteten Abschlussnote einher, wenn die übrigen Variablen konstant gehalten werden. Dieser Effekt ist statistisch nur grenzwertig abgesichert.

Der Koeffizient für `absences` beträgt $-0,019$ mit $p = 0,452$. Unter Kontrolle der übrigen Variablen ist der verbleibende Zusammenhang zwischen Fehlzeiten und Abschlussnote statistisch nicht von 0 unterscheidbar.

Der Koeffizient für `failures` beträgt $-1,685$ mit $p < 0,001$. Jede zusätzliche frühere Misserfolgseinheit geht im Mittel mit einer um etwa 1,69 Punkte niedrigeren erwarteten Abschlussnote einher, bei konstantem `paid`, `freetime`, `absences` und `higher`. Dieser negative Zusammenhang ist klar statistisch von 0 unterscheidbar und stellt den stärksten Prädiktor im Modell dar.

Der Koeffizient für `higheryes` beträgt $2,378$ bei $p < 0,001$. Lernende mit höherer Bildungsaspiration erzielen in diesem Modell im Mittel eine um etwa 2,38 Punkte höhere erwartete Abschlussnote als Lernende ohne höhere Bildungsaspiration, unter Kontrolle der übrigen Variablen. Dieser Effekt ist ebenfalls statistisch deutlich von 0 unterscheidbar.

Das Bestimmtheitsmaß des adjustierten Modells beträgt $R^2 = 0,210$, das adjustierte $R^2 = 0,204$. Die fünf Prädiktoren erklären damit zusammen etwa 21 % der Varianz der Abschlussnoten.

Der geschätzte Koeffizient für `paidyes` beschreibt in diesem Kontext einen adjustierten assoziativen Unterschied zwischen Kindern mit und ohne bezahlte Nachhilfe, unter den im DAG angenommenen Zusammenhängen. Ob dieser Unterschied kausal auf die Nachhilfe zurückzuführen ist, kann mit dem vorliegenden beobachtenden Design nicht sicher entschieden werden. Dies würde zusätzlich voraussetzen, dass das DAG korrekt und vollständig ist, alle relevanten Confounder gemessen sind, keine der Kontrollvariablen als Mediator oder Collider wirkt und keine relevante unbeobachtete Selektion vorliegt.

8. Random Forest

8.1 Random Forest schätzen

Schätzen Sie einen Random Forest zur Vorhersage von `pass`. Schließen Sie G1 und G2 aus.

Trainieren Sie den Random Forest auf 80 Prozent der Daten und testen Sie auf 20 Prozent der Daten.

Durch den Ausschluss von G1 und G2 soll vermieden werden, dass frühere Noten die Vorhersage von `pass` nahezu vollständig dominieren. Trotzdem stehen noch zahlreiche schulische und soziale Merkmale zur Verfügung, sodass das Modell potenziell komplexe nichtlineare Zusammenhänge nutzen kann.

Da `randomForest()` fehlende Prädiktorwerte nicht ohne Weiteres verarbeitet, wird vor dem Modelltraining explizit auf fehlende Werte geprüft. Im verwendeten vorab gecleanten Datensatz liegen keine fehlenden Werte vor; in einer realen Anwendung wäre dieser Schritt jedoch zwingend notwendig. Es wird ein Random Forest mit Standardparametern geschätzt. Dies ist eine bewusste didaktische Vereinfachung, um das Grundprinzip von Random Forests zu illustrieren, ohne die Komplexität durch Hyperparameter-Tuning zu erhöhen.

Beurteilen Sie die Vorhersagegüte anhand der OOB-Fehlerrate (interne Validierung während des Trainings) und der Konfusionsmatrix auf den Testdaten (externe Beurteilung). Erläutern Sie, ob das Modell beide Klassen (`yes` und `no`) gleichermaßen gut vorhersagt, und gehen Sie dabei auf die Unausgewogenheit der Klassen ein.

```
# Zielvariable als Faktor codieren
student$pass <- as.factor(student$pass)

# Datensatz für Random Forest vorbereiten
studentrf <- student

# Direkte Zielvariable sowie konstante Variable entfernen
# course wird ausgeschlossen, da sie im gesamten Datensatz konstant ist ("por")
# und somit keinen Informationsgehalt für die Vorhersage besitzt
studentrf$G3 <- NULL
studentrf$course <- NULL

# Explizite Prüfung auf fehlende Werte in den Prädiktoren
# (im verwendeten Datensatz sollten keine NAs auftreten)
sum(is.na(studentrf))
```

```
[1] 0
```

```
# Datenaufteilung in Trainings- und Testdaten
set.seed(42)
trainIndex <- createDataPartition(studentrf$pass, p = 0.8, list = FALSE)

trainData <- studentrf[trainIndex, ]
testData <- studentrf[-trainIndex, ]
```

```
# Reproduzierbarkeit
set.seed(42)

# Training des Random-Forest-Modells mit Standardparametern
# (bewusste didaktische Vereinfachung, um das Grundprinzip zu illustrieren)
modelrf <- randomForest(pass ~ . - G1 - G2, data = trainData, importance = TRUE)

# Überblick über das Modell (OOB-Fehlerrate)
modelrf
```

```
Call:
randomForest(formula = pass ~ . - G1 - G2, data = trainData,      importance = TRUE)
      Type of random forest: classification
      Number of trees: 500
No. of variables tried at each split: 3

      OOB estimate of  error rate: 15.38%
Confusion matrix:
      no yes class.error
no  16  64  0.800000000
yes 16 424  0.03636364
```

```
# Vorhersage auf den Testdaten
pred_test <- predict(modelrf, newdata = testData)

# Konfusionsmatrix auf den Testdaten (externe Beurteilung)
confusionMatrix(pred_test, testData$pass)
```

Confusion Matrix and Statistics

```
      Reference
Prediction no yes
no         6   3
yes       14 106

      Accuracy : 0.8682
      95% CI   : (0.7974, 0.9213)
No Information Rate : 0.845
P-Value [Acc > NIR] : 0.27759

      Kappa   : 0.3514

McNemar's Test P-Value : 0.01529

      Sensitivity : 0.30000
      Specificity : 0.97248
      Pos Pred Value : 0.66667
      Neg Pred Value : 0.88333
      Prevalence   : 0.15504
      Detection Rate : 0.04651
      Detection Prevalence : 0.06977
      Balanced Accuracy : 0.63624
```

```
'Positive' Class : no
```

Das Modell weist eine OOB-Fehlerrate von 15,38 Prozent auf. Dies ist ein Maß für die interne Vorhersagegüte während des Trainings auf den Trainingsdaten.

Die Konfusionsmatrix auf den Testdaten zeigt eine Accuracy von 86,8 Prozent. Die Klasse yes wird dabei deutlich besser vorhergesagt als die Klasse no: Die Sensitivität für no beträgt nur 0,30, während die Spezifität für yes bei 0,97 liegt. Das Modell erkennt bestandene Fälle also wesentlich zuverlässiger als nicht bestandene Fälle. Dies ist vor allem auf die unausgewogene Klassenverteilung zurückzuführen (ca. 84,6 Prozent yes vs. 15,4 Prozent no in der Stichprobe).

Insgesamt zeigt das Modell damit eine hohe Gesamtgenauigkeit, aber eine schwache Leistung bei der Minority-Klasse no. Für eine bessere Erkennung nicht bestandener Fälle wären zusätzliche Maßnahmen wie eine Gewichtung der Klassen (classwt), eine Anpassung der Stichprobengrößen (sampsize) oder eine Veränderung des Entscheidungsschwellenwerts denkbar.

8.2 Modellgüte bewerten

Bewerten Sie die Güte des Random-Forest-Modells auf den Testdaten. Heben Sie dabei hervor, welche Gütekennzahlen bei starker Klassenungleichheit besonders aussagekräftig sind, und grenzen Sie die externe Testgüte von der internen OOB-Fehlerrate ab.

```
# Beobachtete Werte aus den Testdaten
test.obs <- testData$pass

# Vorhersage auf den Testdaten
test.pred <- predict(modelrf, testData)

# Konfusionsmatrix ausgeben
confusionMatrix(test.pred, test.obs)
```

Confusion Matrix and Statistics

	Reference	
Prediction	no	yes
no	6	3
yes	14	106

Accuracy : 0.8682
95% CI : (0.7974, 0.9213)
No Information Rate : 0.845
P-Value [Acc > NIR] : 0.27759

Kappa : 0.3514

Mcnemar's Test P-Value : 0.01529

Sensitivity : 0.30000
Specificity : 0.97248
Pos Pred Value : 0.66667
Neg Pred Value : 0.88333
Prevalence : 0.15504
Detection Rate : 0.04651
Detection Prevalence : 0.06977
Balanced Accuracy : 0.63624

```
'Positive' Class : no
```

Die OOB-Fehlerrate von 15,38 Prozent aus Abschnitt 8.1 bezieht sich auf die interne Validierung während des Trainings. Die folgende Auswertung der Konfusionsmatrix beurteilt dagegen die Vorhersagegüte auf den separaten Testdaten.

Auf den Testdaten erreicht das Modell eine Accuracy von 86,8 Prozent. Bei der vorliegenden Klassenungleichheit ist diese Kennzahl jedoch nur eingeschränkt aussagekräftig: Die No Information Rate beträgt bereits 84,50 Prozent, und der Unterschied zur beobachteten Accuracy ist mit einem p-Wert von 0,278 nicht statistisch signifikant.

Für die Bewertung sind deshalb insbesondere klassenbezogene Kennzahlen relevant. Die Sensitivity für pass = no beträgt 30,00 Prozent, während die Specificity für pass = yes bei 97,3 Prozent liegt. Von den 20 tatsächlich nicht bestandenen Personen werden somit nur 6 korrekt als no erkannt; 14 werden fälschlich als yes klassifiziert.

Die Balanced Accuracy von 63,6 Prozent und die Kappa-Statistik von 0,351 verdeutlichen, dass die Vorhersageleistung zwischen den beiden Klassen deutlich unausgewogen ist. Für die Modellbewertung sollten daher Balanced Accuracy, Sensitivity und Specificity stärker gewichtet werden als die reine Accuracy. Ergänzend könnten Precision und F1-Score für die Klasse no berichtet werden.

8.3 Variablenwichtigkeit interpretieren

Geben Sie die wichtigsten Prädiktoren des Random Forest aus und interpretieren Sie die Ergebnisse der Variablenwichtigkeit. Machen Sie deutlich, dass sich die Wichtigkeit ausschließlich auf den Beitrag zur Vorhersagegüte in diesem konkreten Modell bezieht und keine kausale Relevanz ausdrückt.

```
# Wichtige Variablen  
importance(modelrf)
```

	no	yes	MeanDecreaseAccuracy	MeanDecreaseGini
school	15.9372354	5.7276359	13.4837941	9.504726
sex	4.5318141	0.6682104	3.1028404	4.225098
Medu	-1.8560619	10.4877053	9.2619494	8.129215
Fedu	-3.3285814	7.2393643	5.2819789	8.315191
studytime	7.6684013	-2.7089924	1.4884291	6.242986
failures	21.6612107	12.5416022	21.4596192	14.914927
paid	0.9257182	2.0490696	2.1490824	1.779147
higher	11.4662553	11.4306755	14.9601908	10.813744
internet	-1.8119105	2.8322218	1.8603156	3.267869
famrel	6.2438578	0.8836545	4.1378363	10.385668
freetime	-0.6223667	-2.9788352	-2.8387960	8.908601
goout	0.7809006	-5.5098739	-4.6129902	9.504377
Walc	3.8981583	1.5505533	3.3055557	10.211814
health	-2.9676138	1.1491198	-0.6048149	8.604942
absences	-1.9203821	-0.4154444	-1.3433075	12.831153


```
# Sortierte Ausgabe nach MeanDecreaseAccuracy  
sort(importance(modelrf)[, "MeanDecreaseAccuracy"], decreasing = TRUE)
```

failures	higher	school	Medu	Fedu	famrel	Walc
21.4596192	14.9601908	13.4837941	9.2619494	5.2819789	4.1378363	3.3055557

```
sex      paid    internet  studytime    health    absences    freetime
3.1028404 2.1490824 1.8603156 1.4884291 -0.6048149 -1.3433075 -2.8387960
goout
-4.6129902
```

```
# Grafik
varImpPlot(modelrf)
```

modelrf



Die wichtigsten Prädiktoren des Random Forest sind nach dem Maß MeanDecreaseAccuracy vor allem failures, higher, school, Medu, Fedu und famrel. Diese Variablen tragen in diesem konkreten Modell besonders stark zur Vorhersagegüte bei. Variablen wie freetime, goout, absences oder health zeigen dagegen nur eine geringe oder sogar negative Bedeutung für die Vorhersagegenauigkeit, da ihre Werte für MeanDecreaseAccuracy nahe bei 0 oder negativ liegen.

Die Variablenwichtigkeit sollte hier nicht kausal interpretiert werden. Sie zeigt nur, welche Merkmale innerhalb dieses Random-Forest-Modells zur Vorhersage von pass beitragen. Die Ergebnisse hängen zudem von der Datenaufteilung, den gewählten Modellparametern, der Klassenungleichheit und dem Umgang mit fehlenden Werten ab.

Die beiden Wichtigkeitsmaße können unterschiedliche Rangfolgen liefern: MeanDecreaseAccuracy bewertet den Beitrag einer Variable zur Vorhersagegenauigkeit, während MeanDecreaseGini die durchschnittliche Verbesserung der Knotenreinheit misst. Für die Interpretation ist daher vor allem die gemeinsame Betrachtung beider Maße sinnvoll.