

Statistische Modellierung | Fallstudie Student Performance – Musterlösung

Dozent:in, FOM Hochschule

2026-07-01

Inhaltsverzeichnis

Fallstudie Student Performance – Portugiesisch-Kurs	2
1. Erste Schritte	2
1.1 Datentabelle erschließen	2
1.2 Skalenniveau bestimmen	3
1.3 Messung beurteilen	4
2. Explorative Datenanalyse einer kategorialen Variable	4
2.1 Häufigkeitstabelle erstellen	4
2.2 Säulendiagramm erstellen	5
3. Explorative Datenanalyse von G3	5
3.1 Kennwerte berechnen	5
3.2 Histogramm erstellen und interpretieren	6
3.3 Zusammenhang zwischen freetime und G3	6
4. Inferenzstatistik	7
4.1 Bootstrap für den Mittelwert von G3	7
4.2 Histogramm der Bootstrap-Verteilung	8
4.3 Mittelwertvergleich für internet	9
4.4 Permutationsverteilung für internet	9
4.5 Bootstrap für die Korrelation zwischen studytime und G3	11
4.6 Histogramm der Bootstrap-Korrelationen	11
5. Bayes-Statistik	12
5.1 Binäre Variable Pass erzeugen	12
5.2 Informative Prior darstellen	13
5.3 Likelihood-Funktion darstellen	13
5.4 Posteriori-Verteilung bestimmen	14
5.5 Priorvergleich durchführen	16
6. Lineare Regression	17
6.1 Einfache lineare Regression	17
6.2 Multiple lineare Regression	18
6.3 Interaktionsmodell	19
7. Kausale Modellierung	20
7.1 Naives Modell für paid	20
7.2 Adjustiertes Modell für paid	21
8. Random Forest	23
8.1 Random Forest schätzen	23
8.2 Modellgüte bewerten	24
8.3 Variablenwichtigkeit interpretieren	25

```
# Benötigte Pakete laden
library(mosaic)
library(psych)
library(tidyr)
library(here)
library(caret)
library(randomForest)
library(corrplot)
library(dagitty)

# Datentabelle einlesen
student <- read.csv(here("data", "student-por-clean.csv"))
```

Fallstudie Student Performance – Portugiesisch-Kurs

1. Erste Schritte

1.1 Datentabelle erschließen

Für diese Fallstudie arbeiten Sie mit Daten zum schulischen Leistungsverhalten von Schülerinnen und Schülern einer portugiesischen Sekundarschule. Bevor Sie mit den eigentlichen Analysen beginnen, soll zunächst die Datenbasis systematisch erschlossen werden. Ermitteln Sie, wie viele Beobachtungen und wie viele Variablen die Datentabelle enthält. Nennen Sie außerdem die in der Datentabelle enthaltenen Variablen und beschreiben Sie die Beobachtungseinheit.

```
# Struktur der Datentabelle anzeigen
str(student)
```

```
'data.frame': 649 obs. of 19 variables:
 $ school : chr "GP" "GP" "GP" "GP" ...
 $ sex : chr "F" "F" "F" "F" ...
 $ Medu : int 4 1 1 4 3 4 2 4 3 3 ...
 $ Fedu : int 4 1 1 2 3 3 2 4 2 4 ...
 $ studytime: int 2 2 2 3 2 2 2 2 2 2 ...
 $ failures : int 0 0 0 0 0 0 0 0 0 0 ...
 $ paid : chr "no" "no" "no" "no" ...
 $ higher : chr "yes" "yes" "yes" "yes" ...
 $ internet : chr "no" "yes" "yes" "yes" ...
 $ famrel : int 4 5 4 3 4 5 4 4 4 5 ...
 $ freetime : int 3 3 3 2 3 4 4 1 2 5 ...
 $ goout : int 4 3 2 2 2 2 4 4 2 1 ...
 $ Walc : int 1 1 3 1 2 2 1 1 1 1 ...
 $ health : int 3 3 3 5 5 5 3 1 1 5 ...
 $ absences : int 4 2 6 0 0 6 0 2 0 0 ...
 $ G1 : int 0 9 12 14 11 12 13 10 15 12 ...
 $ G2 : int 11 11 13 14 13 12 12 13 16 12 ...
 $ G3 : int 11 11 12 14 13 13 13 13 17 13 ...
 $ course : chr "por" "por" "por" "por" ...
```

```
# Erste Fälle der Datentabelle anzeigen
head(student)
```

	school	sex	Medu	Fedu	studytime	failures	paid	higher	internet	famrel	freetime
1	GP	F	4	4	2	0	no	yes	no	4	3

2	GP	F	1	1	2	0	no	yes	yes	5	3
3	GP	F	1	1	2	0	no	yes	yes	4	3
4	GP	F	4	2	3	0	no	yes	yes	3	2
5	GP	F	3	3	2	0	no	yes	no	4	3
6	GP	M	4	3	2	0	no	yes	yes	5	4
goout Walc health absences G1 G2 G3 course											
1	4	1	3	4	0	11	11	por			
2	3	1	3	2	9	11	11	por			
3	2	3	3	6	12	13	12	por			
4	2	1	5	0	14	14	14	por			
5	2	2	5	0	11	13	13	por			
6	2	2	5	6	12	12	13	por			

```
# Anzahl der Beobachtungen bestimmen
nrow(student)
```

```
[1] 649
```

```
# Anzahl der Variablen bestimmen
ncol(student)
```

```
[1] 19
```

```
# Variablennamen ausgeben
names(student)
```

```
[1] "school"    "sex"       "Medu"      "Fedu"      "studytime" "failures"
[7] "paid"      "higher"    "internet"  "famrel"    "freetime"  "goout"
[13] "Walc"      "health"    "absences"  "G1"        "G2"        "G3"
[19] "course"
```

Die Datentabelle umfasst 649 Beobachtungen und 19 Variablen; enthalten sind school, sex, Medu, Fedu, studytime, failures, paid, higher, internet, famrel, freetime, goout, Walc, health, absences, G1, G2, G3 und course. Die Beobachtungseinheit ist jeweils eine einzelne Schülerin bzw. ein einzelner Schüler, da jede Zeile genau eine Person mit ihren Merkmalsausprägungen beschreibt.

1.2 Skalenniveau bestimmen

Bestimmen Sie für die Variablen studytime, absences, internet, higher, sex, G3, famrel, goout und health jeweils das Skalenniveau und beschreiben Sie die Information der Variable.

- studytime: kategorial, ordinalskaliert; die Variable gibt die wöchentliche Lernzeit in geordneten Kategorien an: 1 = < 2 Stunden, 2 = 2 bis 5 Stunden, 3 = 5 bis 10 Stunden, 4 = > 10 Stunden.
- absences: metrisch, verhältnisskaliert; die Variable beschreibt die Anzahl der Fehlzeiten.
- internet: kategorial, nominalskaliert; die Variable gibt an, ob zu Hause Internetzugang vorhanden ist, mit den Ausprägungen yes und no.
- higher: kategorial, nominalskaliert; die Variable beschreibt, ob eine Person eine höhere Bildung anstrebt, mit den Ausprägungen yes und no.
- sex: kategorial, nominalskaliert; die Variable beschreibt das Geschlecht mit den Ausprägungen F = weiblich und M = männlich.

- G3: metrisch, im Folgenden intervallskaliert behandelt; die Variable enthält die Abschlussnote im Portugiesisch-Kurs.
- famrel: kategorial, ordinalskaliert; die Variable beschreibt die Qualität der Familienbeziehungen auf einer geordneten Skala von 1 = sehr schlecht bis 5 = ausgezeichnet.
- goout: kategorial, ordinalskaliert; die Variable gibt an, wie häufig eine Person mit Freundinnen und Freunden ausgeht, auf einer Skala von 1 = sehr selten bis 5 = sehr häufig.
- health: kategorial, ordinalskaliert; die Variable beschreibt den aktuellen Gesundheitszustand auf einer geordneten Skala von 1 = sehr schlecht bis 5 = sehr gut.

1.3 Messung beurteilen

Beurteilen Sie die Variablen `studytime`, `famrel`, `goout` und `health` im Hinblick auf mögliche Messprobleme. Gehen Sie dabei insbesondere auf Präzision, Validität und mögliche Verzerrungen ein.

`studytime` erfasst Lernaufwand nur in wenigen geordneten Kategorien und ist deshalb relativ grob gemessen; Unterschiede innerhalb einer Kategorie bleiben unsichtbar. `famrel`, `goout` und `health` beruhen auf subjektiven Selbsteinschätzungen, sodass gleiche Antwortkategorien von verschiedenen Personen unterschiedlich interpretiert werden können. Damit sind sowohl begrenzte Präzision als auch Validitätsprobleme möglich; zusätzlich können soziale Erwünschtheit, Erinnerungslücken und individuelle Antworttendenzen die Messung verzerren. Für explorative Analysen sind die Variablen dennoch gut nutzbar, Ergebnisse sollten aber nicht als fehlerfreie Messungen verstanden werden.

2. Explorative Datenanalyse einer kategorialen Variable

2.1 Häufigkeitstabelle erstellen

Analysieren Sie ausschließlich die Variable `higher`; die Variable beschreibt, ob eine Person eine höhere Bildung anstrebt. Erstellen Sie eine relative und eine absolute Häufigkeitstabelle, die die jeweiligen Werte jeder Kategorie der Variable enthält.

```
# Absolute Häufigkeiten von higher berechnen
higherabs <- tally(~ higher, data = student)

# Relative Häufigkeiten von higher berechnen
higherrel <- tally(~ higher, data = student, format = "proportion")

# Ausgabe
higherabs
```

```
higher
no yes
69 580
```

```
higherrel
```


```
higher
no      yes
0.1063174 0.8936826
```

Die Variable `higher` ist in der Stichprobe sehr unausgewogen verteilt. Von 649 Schülerinnen und Schülern geben 580 Personen (89,37 Prozent) an, eine höhere Bildung anzustreben, während nur 69 Personen (10,63 Prozent) dies verneinen. Für spätere Analysen bedeutet das, dass die Kategorie `yes` die Daten klar dominiert.

2.2 Säulendiagramm erstellen

Erstellen Sie ein Säulendiagramm der absoluten Häufigkeiten von higher. Beschreiben Sie die Verteilung von higher auf Basis der Tabelle und des Säulendiagramms. Gehen Sie dabei insbesondere auf die häufigere Kategorie und die generelle Verteilung ein.

```
# Säulendiagramm der absoluten Häufigkeiten von higher erstellen
gf_bar(~ higher, data = student)
```



Das Säulendiagramm macht die starke Dominanz der Kategorie yes unmittelbar sichtbar. Der Balken für yes ist mit 580 Fällen mehr als achtmal so hoch wie der Balken für no mit 69 Fällen. Grafisch bestätigt sich damit, dass der Wunsch nach höherer Bildung in dieser Stichprobe der Regelfall ist. Mit einem Anteil von 89,37 Prozent ist die Verteilung deutlich auf eine Kategorie konzentriert. Inhaltlich spricht das dafür, dass Bildungsaspirationen in dieser Gruppe sehr verbreitet sind und nur eine kleine Minderheit keine höhere Bildung anstrebt.

3. Explorative Datenanalyse von G3

3.1 Kennwerte berechnen

Analysieren Sie als nächstes die Variable G3, welche die Abschlussnote im Fach „Portugiesisch“ beschreibt. Berechnen Sie für G3 die folgenden Kennwerte: Mittelwert, Median, Standardabweichung, Minimum, Maximum, 25-Quantil, 75-Quantil und Interquartilsabstand. Interpretieren Sie die Werte anschließend.

```
# Zentrale Kennwerte für G3 berechnen
g3stats <- favstats(~ G3, data = student)
g3stats
```

min	Q1	median	Q3	max	mean	sd	n	missing
0	10	12	14	19	11.90601	3.230656	649	0

```
# Interquartilsabstand berechnen
g3stats$Q3 - g3stats$Q1
```


```
[1] 4
```

Die Abschlussnote G3 hat einen Mittelwert von 11.91, einen Median von 12 und eine Standardabweichung von 3.23. Die Werte reichen von 0 bis 19 Punkten; das 25-Prozent-Quantil liegt bei 10 und das 75-Prozent-Quantil bei 14, sodass der Interquartilsabstand 4 Punkte beträgt. Damit liegen die mittleren 50 Prozent der Abschlussnoten zwischen 10 und 14 Punkten, also grob im mittleren bis leicht oberen Leistungsbereich.

3.2 Histogramm erstellen und interpretieren

Erstellen Sie ein Histogramm von G3 und beschreiben Sie anschließend, welche Form die Verteilung aufweist. Gehen Sie dabei insbesondere auf Schiefe sowie auf die Frage ein, in welchen Wertebereichen sich viele beziehungsweise wenige Beobachtungen befinden. Benennen Sie den Modus.

```
# Histogramm zur Verteilung von G3 erstellen  
gf_histogram(~ G3, data = student, bins = 12)
```



```
# Schiefe ergänzend berechnen  
skew(student$G3)
```


```
[1] -0.9086938
```

Die Verteilung von G3 ist nicht perfekt symmetrisch, sondern moderat linksschief mit einer Schiefe von -0.909 . Der Modus liegt mit ca. 200 Beobachtungen bei 10 und deutlich mehr als die Hälfte der Beobachtungen haben eine Note von 10 oder höher. Das theoretische Maximum von 20 Punkten wurde von keiner Schülerin und von keinem Schüler erreicht.

3.3 Zusammenhang zwischen freetime und G3

Untersuchen Sie den Zusammenhang zwischen freetime und G3. Erstellen Sie ein Streudiagramm und berechnen Sie zusätzlich die Pearson-Korrelation.

```
# Streudiagramm erstellen  
gf_point(G3 ~ freetime, data = student)
```



```
# Pearson-Korrelation berechnen
cor(G3 ~ freetime, data = student)
```

```
[1] -0.1227049
```

Zwischen Abschlussnote und freier Zeit besteht ein negativer, aber nur schwacher linearer Zusammenhang. Die Pearson-Korrelation beträgt -0.123 ; weniger Freizeit geht also tendenziell mit besseren Abschlussnoten einher. Im Streudiagramm lässt sich dieser Trend nur schwer erkennen. Die Noten streuen innerhalb jeder Freizeitstufe deutlich.

4. Inferenzstatistik

4.1 Bootstrap für den Mittelwert von G3

Bestimmen Sie für den Mittelwert von G3 mithilfe eines Bootstrap-Verfahrens den Standardfehler und ein 95-Prozent-Konfidenzintervall.

```
# Beobachteten Mittelwert berechnen
meang3 <- mean(~ G3, data = student)

# Bootstrap-Verteilung erzeugen
set.seed(12345)
bootg3 <- do(1000) * mean(~ G3, data = resample(student))

# Erste Fälle anzeigen
head(bootg3)
```

```
      mean
1 11.99076
2 12.01233
3 12.12943
4 12.06780
5 11.81048
6 12.15100
```

```
# Standardfehler bestimmen  
sd(~ mean, data = bootg3)
```

```
[1] 0.1246217
```

```
# 95-Prozent-Konfidenzintervall bestimmen  
qdata(~ mean, p = c(0.025, 0.975), data = bootg3)
```


```
2.5%    97.5%  
11.65636 12.13559
```

Der gebootstrapte Standardfehler des Mittelwerts beträgt 0.124 Punkte. Das 95-Prozent-Konfidenzintervall für den mittleren G3-Wert reicht von 11.66 bis 12.14 Punkten. Der Stichprobenmittelwert von 11.91 ist damit relativ präzise geschätzt; bei wiederholten Stichproben wäre nur mit moderaten Schwankungen des Mittelwerts zu rechnen.

4.2 Histogramm der Bootstrap-Verteilung

Stellen Sie die Bootstrap-Verteilung der Mittelwerte grafisch dar und markieren Sie Mittelwert und Intervallgrenzen.

```
# Konfidenzintervall speichern  
kig3 <- qdata(~ mean, p = c(0.025, 0.975), data = bootg3)  
  
# Histogramm der Bootstrap-Verteilung zeichnen  
gf_histogram(~ mean, data = bootg3, bins = 20) |>  
  gf_vline(xintercept = meang3, color = "red") |>  
  gf_vline(xintercept = kig3, linetype = "dashed", color = "blue")
```



Die Bootstrap-Verteilung der Mittelwerte ist annähernd glockenförmig um den beobachteten Mittelwert von 11,91 zentriert. Die rote Linie markiert diesen Mittelwert, die blauen gestrichelten Linien des 95-prozentigen Intervalls liegen bei 11.658 und 12.143. Da die Verteilung relativ kompakt ist, bestätigt die Grafik die vergleichsweise präzise Schätzung des durchschnittlichen Leistungsniveaus.

4.3 Mittelwertvergleich für internet

Untersuchen Sie mithilfe einer linearen Regression, ob sich die mittlere Abschlussnote G3 zwischen internet = yes und internet = no unterscheidet.

```
# Referenzkategorie festlegen
student$internet <- factor(student$internet, levels = c("no", "yes"))

# Lineares Modell schätzen
modinternet <- lm(G3 ~ internet, data = student)

# Modellzusammenfassung ausgeben
summary(modinternet)
```

```
Call:
lm(formula = G3 ~ internet, data = student)

Residuals:
    Min       1Q   Median       3Q      Max
-12.1727  -2.0265  -0.1727   1.8273   7.9735

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  11.0265     0.2601  42.39  < 2e-16 ***
internetyes   1.1462     0.2970   3.86 0.000125 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.197 on 647 degrees of freedom
Multiple R-squared:  0.02251, Adjusted R-squared:  0.021
F-statistic: 14.9 on 1 and 647 DF, p-value: 0.0001249
```

```
# Beobachteten Koeffizienten ausgeben
coef(modinternet)
```

```
(Intercept) internetyes
 11.026490    1.146201
```

Schülerinnen und Schüler mit Internetzugang erreichen im Mittel 12.17 Punkte, ohne Internetzugang 11.03 Punkte. Der Intercept beschreibt den Mittelwert der Referenzgruppe internet = no und beträgt 11.03 Punkte. Der Koeffizient für internetyes beträgt 1.146 Punkte und beschreibt damit einen positiven Mittelwertunterschied zugunsten der Gruppe mit Internetzugang. Der Unterschied ist mit einem p-Wert von $p < 0.001$ statistisch auffällig, sodass die Daten hier auf einen systematischen Mittelwertunterschied hindeuten.

4.4 Permutationsverteilung für internet

Formulieren Sie für den Koeffizienten von internet im linearen Regressionsmodell $G3 \sim \text{internet}$ die Nullhypothese und die Alternativhypothese. Erzeugen Sie anschließend eine Permutationsverteilung für diesen Koeffizienten, bestimmen Sie den p-Wert und treffen Sie eine Entscheidung auf dem 5%-Niveau. Gehen Sie davon aus, dass unter der Nullhypothese kein Zusammenhang besteht und die Gruppenzugehörigkeit zufällig ist. Mischen Sie daher die Variable internet mehrfach neu, während die Noten gleich bleiben, und berechnen Sie jeweils den Koeffizienten des linearen Modells. Visualisieren Sie die resultierende Permutationsverteilung in einem Histogramm und markieren Sie den beobachteten Koeffizienten, um seine Lage im Vergleich zur Nullverteilung zu beurteilen.

```
set.seed(12345)
perminternet <- do(1000) * lm(G3 ~ shuffle(internet), data = student)


# Spaltennamen prüfen
names(perminternet)
```

```
[1] "Intercept"  "internetyes" "sigma"      "r.squared"   "F"
[6] "numdf"      "dendf"       ".row"       ".index"
```

```
# Zweite Spalte umbenennen
names(perminternet)[2] <- "internetperm"

# Beobachteten Koeffizienten speichern
binternetnet <- coef(modinternet)[2]

# Histogramm
gf_histogram(~ internetperm, data = perminternet, bins = 30) |>
  gf_vline(xintercept = binternetnet, color = "red")
```



```
# p-Wert
mean(abs(perminternet$internetperm) >= abs(binternetnet))
```

```
[1] 0
```

Die Nullhypothese lautet $H_0 : \beta_{\text{internet}} = 0$; es besteht kein Unterschied in der mittleren Abschlussnote zwischen Schülerinnen und Schülern mit und ohne Internetzugang. Die Alternativhypothese lautet $H_1 : \beta_{\text{internet}} \neq 0$; es besteht also ein Unterschied.

Der beobachtete Koeffizient beträgt 1,146 Punkte und liegt weit außerhalb der unter der Nullhypothese erwarteten Permutationsverteilung. Der permutationsbasierte p-Wert beträgt $p < 0.001$.

Da der p-Wert kleiner als 0.05 ist, wird die Nullhypothese auf dem 5%-Niveau verworfen. Es gibt somit statistische Hinweise auf einen Unterschied in den mittleren Abschlussnoten zwischen den beiden Gruppen.

4.5 Bootstrap für die Korrelation zwischen studytime und G3

Bestimmen Sie für die Korrelation zwischen studytime und G3 einen Bootstrap-Standardfehler und ein 95-Prozent-Konfidenzintervall.

```
# Beobachtete Korrelation berechnen
rbeob <- cor(G3 ~ studytime, data = student)
rbeob
```

```
[1] 0.2497887
```

```
# Bootstrap-Verteilung erzeugen
set.seed(12345)
bootcor <- do(1000) * cor(G3 ~ studytime, data = resample(student))

# Erste Fälle anzeigen
head(bootcor)
```

```
      cor
1 0.2471512
2 0.2533238
3 0.2583629
4 0.2620428
5 0.2497867
6 0.2112117
```

```
# Standardfehler bestimmen
sd(~ cor, data = bootcor)
```

```
[1] 0.03436534
```

```
# 95-Prozent-Konfidenzintervall bestimmen
qdata(~ cor, p = c(0.025, 0.975), data = bootcor)
```

```
      2.5%      97.5%
0.1800522 0.3153366
```


Für die Korrelation ergibt sich ein Bootstrap-Standardfehler von 0.034. Das 95-Prozent-Konfidenzintervall reicht von 0.182 bis 0.315. Da das gesamte Intervall oberhalb von 0 liegt, spricht das für einen robust positiven Zusammenhang zwischen Lernzeit und Abschlussnote, auch wenn dessen Stärke eher moderat bleibt.

4.6 Histogramm der Bootstrap-Korrelationen

Stellen Sie die Bootstrap-Verteilung der Korrelationen grafisch dar.

```
# Konfidenzintervall speichern
kir <- qdata(~ cor, p = c(0.025, 0.975), data = bootcor)

# Histogramm der Bootstrap-Korrelationen zeichnen
gf_histogram(~ cor, data = bootcor, bins = 20) |>
  gf_vline(xintercept = rbeob, color = "red") |>
  gf_vline(xintercept = kir, linetype = "dashed", color = "blue")
```



Die Bootstrap-Verteilung der Korrelationen ist um den beobachteten Wert von 0.250 zentriert. Die blauen Intervallgrenzen bei 0.182 und 0.315 liegen beide im positiven Bereich. Grafisch unterstreicht das, dass ein negativer Zusammenhang mit diesen Daten wenig plausibel ist.

5. Bayes-Statistik

5.1 Binäre Variable Pass erzeugen

Erzeugen Sie aus G3 die binäre Variable Pass, wobei $G3 \geq 10$ als bestanden gilt. Lassen Sie sich anschließend deren absoluten und relativen Häufigkeiten ausgeben und bestimmen Sie den Erfolgsanteil.

```
# Binäre Variable Pass erzeugen
student$Pass <- ifelse(student$G3 >= 10, "yes", "no")

# Absolute Häufigkeiten ausgeben
tally(~ Pass, data = student)
```

```
Pass
no yes
100 549
```

```
# Relative Häufigkeiten ausgeben
tally(~ Pass, data = student, format = "proportion")
```

```
Pass
no      yes
0.1540832 0.8459168
```

```
# Erfolgsanteil bestimmen
n <- nrow(student)
y <- sum(student$Pass == "yes")
erfolgsanteil <- y / n
erfolgsanteil
```

```
[1] 0.8459168
```

Nach der Dichotomisierung gelten 549 von 649 Schülerinnen und Schülern als bestanden; das entspricht 84,59 Prozent. Nicht bestanden haben 100 Personen beziehungsweise 15,41 Prozent. Der beobachtete Anteil der Bestandenen in der Stichprobe liegt bei 84,59% und somit über 50%.

5.2 Informative Prior darstellen


Legen Sie für den Erfolgsanteil für Schülerinnen und Schüler, die bestanden haben, eine informative Beta-Prior fest und stellen Sie diese grafisch dar.

```
# Werte für pi bereitstellen
ppi <- seq(from = 0, to = 1, by = 1/1000)

# alpha_prior und beta_prior spezifizieren
a_prior <- 8
b_prior <- 2

# Dichtevektor der Prior
dppi_prior <- dbeta(ppi, shape1 = a_prior, shape2 = b_prior)

# zeichnen
gf_line(dppi_prior ~ ppi) |>
  gf_labs(x = expression(pi), y = expression(f(pi)),
          title = paste0("Beta(", a_prior, ", ", b_prior, ")"))
```



Die Beta-Prior mit Parametern 8 und 2 legt vor der Datensicht bereits relativ hohe Erfolgswahrscheinlichkeiten nahe. Ihr Erwartungswert liegt bei 0.80 und passt damit gut zu einer Annahme, dass die Mehrheit der Lernenden besteht. Die Prior ist zugleich informativ genug, um kleine Stichproben sichtbar zu beeinflussen, wird hier aber auf eine recht große Stichprobe treffen.

5.3 Likelihood-Funktion darstellen

Stellen Sie die Likelihood-Funktion für den Erfolgsanteil π auf Basis der beobachteten Daten dar und bestimmen Sie den Maximum-Likelihood-Schätzer. Stellen Sie die Likelihood-Funktion zusätzlich als Grafik dar.


```
# n und y angeben
n <- 649
y <- 549

# Likelihood berechnen
lppi <- dbinom(y, size = n, prob = ppi)

# Maximum-Likelihood-Schätzer
mle <- y / n
mle
```

```
[1] 0.8459168
```

```
# zeichnen
gf_line(lppi ~ ppi) |>
  gf_labs(x = expression(pi), y = "Likelihood",
    title = "Likelihood-Funktion") |>
  gf_vline(xintercept = mle, color = "red")
```



Die Likelihood-Funktion gibt an, wie plausibel jeder mögliche Wert von π ist, gegeben die beobachteten Daten. Sie basiert auf der Binomialverteilung $Y \sim \text{Binom}(n, \pi)$ und wird für alle $\pi \in [0, 1]$ ausgewertet. Der Maximum-Likelihood-Schätzer ergibt sich als $\hat{\pi} = \frac{y}{n} = \frac{549}{649} \approx 0,846$ und entspricht damit direkt dem beobachteten Erfolgsanteil in der Stichprobe. Die rote gestrichelte Linie im Plot markiert diesen Wert, an dem die Likelihood ihr Maximum erreicht.


5.4 Posteriori-Verteilung bestimmen

Bestimmen Sie auf Basis der Daten die Posteriori-Verteilung sowie den Posterior-Modus und ein 95-Prozent-Kreditintervall.

```
# alpha_post und beta_post berechnen
a_post <- a_prior + y
b_post <- b_prior + (n - y)
```

```
# Dichtevektor
dppi <- dbeta(ppi, shape1 = a_post, shape2 = b_post)

# zeichnen
gf_line(dppi ~ ppi) |>
  gf_labs(x = expression(pi), y = expression(f(pi)),
    title = paste0("Beta(", a_post, ", ", b_post, ")"))
```




```
# Modus (Punktschätzer)
modus <- (a_post - 1) / (a_post + b_post - 2)
modus
```

```
[1] 0.8462709
```

```
# 95%-Kredibilitätsintervall
kred95 <- qbeta(c(0.025, 0.975), a_post, b_post)
kred95
```

```
[1] 0.8166559 0.8718001
```

```
# zeichnen mit Modus und Intervall
gf_line(dppi ~ ppi) |>
  gf_labs(x = expression(pi), y = expression(f(pi)),
    title = paste0("Beta(", a_post, ", ", b_post, ")")) |>
  gf_vline(xintercept = modus, color = "blue") |>
  gf_vline(xintercept = kred95, color = "green")
```



Unter Einbezug der Daten ergibt sich die Posteriori-Verteilung Beta(557, 102). Der Posterior-Modus beträgt 0.846 und das 95-Prozent-Kreditabilitätsintervall reicht von 0.817 bis 0.872. Bayesianisch betrachtet liegt der Erfolgsanteil damit sehr wahrscheinlich im Bereich von rund 81,67 bis 87,18 Prozent und klar oberhalb einer bloßen Zufallserwartung von 50 Prozent.

5.5 Priorvergleich durchführen

Vergleichen Sie die Auswirkungen der informativen Prior mit einer nicht informativen Prior(1,1), indem Sie beide Posteriori-Verteilungen grafisch vergleichen.


```
# nicht informative Prior spezifizieren
a_prior2 <- 1
b_prior2 <- 1

# alpha_post und beta_post für die zweite Prior berechnen
a_post2 <- a_prior2 + y
b_post2 <- b_prior2 + (n - y)

# Dichtevektor der zweiten Posteriorverteilung
dppi2 <- dbeta(ppi, shape1 = a_post2, shape2 = b_post2)

# beide Posteriorverteilungen zeichnen
gf_line(dppi ~ ppi, color = "red") |>
  gf_line(dppi2 ~ ppi, color = "blue") |>
  gf_labs(x = expression(pi), y = expression(f(pi)),
          title = "Posteriorvergleich")
```


Posteriorvergleich



Die Posteriorverteilung unter der informativen Prior(557,102) unterscheidet sich nur gering von der Posteriorverteilung unter der uniformen Prior Beta(550, 101), wie sich an dem sehr ähnlichen Kurvenverlauf ablesen lässt. Das zeigt, dass die Daten mit 649 Beobachtungen deutlich informativer sind als die Vorannahmen. Inhaltlich ist das Ergebnis also robust gegenüber einer plausiblen Variation der Priorwahl.

6. Lineare Regression

6.1 Einfache lineare Regression

Schätzen Sie das lineare Regressionsmodell $G3 \sim \text{studytime}$, geben Sie die wichtigsten Ergebnisse aus und interpretieren Sie diese. Nehmen Sie außerdem eine Punktprognose für einen Schüler vor der wöchentlich 5-10 Stunden lernt (also Ausprägung 3 hat).

```
# Einfaches lineares Regressionsmodell schätzen
mod1 <- lm(G3 ~ studytime, data = student)

# Modellzusammenfassung ausgeben
summary(mod1)
```

```
Call:
lm(formula = G3 ~ studytime, data = student)

Residuals:
    Min       1Q   Median       3Q      Max
-11.9735  -1.9463   0.0265   2.0265   7.0265

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  10.0278     0.3115   32.191 < 2e-16 ***
studytime     0.9728     0.1483    6.562 1.09e-10 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.131 on 647 degrees of freedom
```

```
Multiple R-squared:  0.06239,   Adjusted R-squared:  0.06095  
F-statistic: 43.06 on 1 and 647 DF,  p-value: 1.091e-10
```

```
# Koeffizienten ausgeben  
coef(mod1)
```

```
(Intercept)    studytime  
10.0277805     0.9728416
```

```
# Bestimmtheitsmaß ausgeben  
rsquared(mod1)
```

```
[1] 0.06239439
```

```
# Punktprognose für studytime = 3 berechnen  
predict(mod1, newdata = data.frame(studytime = 3))
```

```
1  
12.94631
```

Im einfachen linearen Regressionsmodell beträgt die Konstante 10.028 und der Koeffizient von studytime 0.973. Eine zusätzliche Lernzeitstufe geht damit im Mittel mit rund 0.973 Punkten höherer Abschlussnote einher. Das Bestimmtheitsmaß liegt bei 0.061, sodass studytime allein mit 6,2 Prozent der Varianz nur einen kleinen Teil der Notenunterschiede erklärt. Für studytime = 3 ergibt sich eine Punktprognose von 12,946 Punkten.

6.2 Multiple lineare Regression

Schätzen Sie das multiple Modell $G3 \sim \text{studytime} + \text{absences} + \text{failures} + \text{internet}$.

```
# Multiples lineares Regressionsmodell schätzen  
mod2 <- lm(G3 ~ studytime + absences + failures + internet, data = student)  
  
# Modellzusammenfassung ausgeben  
summary(mod2)
```

```
Call:  
lm(formula = G3 ~ studytime + absences + failures + internet,  
    data = student)
```

```
Residuals:  
      Min       1Q   Median       3Q      Max  
-12.6645  -1.6413   0.0683   1.6886   7.7471
```

```
Coefficients:  
              Estimate Std. Error t value Pr(>|t|)  
(Intercept) 10.33128     0.37500  27.550 < 2e-16 ***  
studytime    0.73982     0.13914   5.317 1.46e-07 ***  
absences     -0.02323     0.02486  -0.934  0.35043  
failures     -1.90909     0.19553  -9.764 < 2e-16 ***
```

```
internetyes  0.85357    0.27065    3.154  0.00169 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.889 on 644 degrees of freedom
Multiple R-squared:  0.2051,    Adjusted R-squared:  0.2002
F-statistic: 41.55 on 4 and 644 DF,  p-value: < 2.2e-16
```

```
# Koeffizienten ausgeben
coef(mod2)
```

```
(Intercept)  studytime  absences  failures internetyes
10.33127904  0.73982415 -0.02322877 -1.90909251  0.85357008
```

```
# Bestimmtheitsmaß ausgeben
rsquared(mod2)
```

```
[1] 0.2051408
```

Im multiplen Modell steigt das Bestimmtheitsmaß auf 0.205 und liegt damit deutlich über dem einfachen Modell mit über einem Fünftel erklärter Varianz. *studytime* wirkt weiterhin positiv (0.740), *absences* negativ (-0.023) und *failures* klar negativ (-1.909). Der Koeffizient für *internetyes* beträgt 0.854 und ist inhaltlich kleiner als im bivariaten Modell; der stärkste negative Prädiktor im Modell sind die bisherigen Misserfolge *failures*.

6.3 Interaktionsmodell

Schätzen Sie ein Modell mit Wechselwirkung zwischen *studytime* und *internet*.

```
# Interaktionsmodell schätzen
mod3 <- lm(G3 ~ studytime * internet + absences + failures, data = student)

# Modellzusammenfassung ausgeben
summary(mod3)
```

```
Call:
lm(formula = G3 ~ studytime * internet + absences + failures,
    data = student)

Residuals:
    Min       1Q   Median       3Q      Max
-12.6626  -1.6403   0.0225   1.6711   7.6364

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)    10.56489    0.59892   17.640  <2e-16 ***
studytime         0.61334    0.28855    2.126  0.0339 *
internetyes       0.54213    0.67870    0.799  0.4247
absences        -0.02231    0.02494   -0.894  0.3715
failures        -1.90730    0.19567   -9.747  <2e-16 ***
studytime:internetyes  0.16445    0.32861    0.500  0.6169
---

```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 2.891 on 643 degrees of freedom  
Multiple R-squared:  0.2055,    Adjusted R-squared:  0.1993  
F-statistic: 33.25 on 5 and 643 DF,  p-value: < 2.2e-16
```

```
# Koeffizienten ausgeben  
coef(mod3)
```

(Intercept)	studytime	internetyes
10.56489184	0.61334362	0.54212841
absences	failures	studytime:internetyes
-0.02230681	-1.90729866	0.16444883

```
# Bestimmtheitsmaß ausgeben  
rsquared(mod3)
```

```
[1] 0.2054502
```

Das Interaktionsmodell erreicht ein Bestimmtheitsmaß von 0.205 und verbessert sich damit nicht merklich gegenüber dem Modell ohne Interaktion. Der Interaktionsterm `studytime:internetyes` beträgt 0.164. Inhaltlich bedeutet das: Der positive Zusammenhang zwischen Lernzeit und Abschlussnote unterscheidet sich zwischen Lernenden mit und ohne Internetzugang höchstens geringfügig. Die zentralen Leistungsunterschiede werden weiterhin vor allem durch Fehlzeiten und insbesondere durch frühere Misserfolge erklärt.

7. Kausale Modellierung

7.1 Naives Modell für paid

Schätzen Sie ein bivariates Modell für den Zusammenhang zwischen `paid` also bezahlter Nachhilfe und der Abschlussnote `G3`. Erstellen Sie zuvor ein DAG, dass diesen Zusammenhang modelliert. Das zugehörige DAG kann auf der Website [DAGitty.net](https://dagitty.net) grafisch erstellt und dargestellt werden.

```
# Referenzkategorie festlegen  
student$paid <- factor(student$paid, levels = c("no", "yes"))  
  
# Naives Modell schätzen  
modpaid1 <- lm(G3 ~ paid, data = student)  
  
# Modellzusammenfassung ausgeben  
summary(modpaid1)
```

```
Call:  
lm(formula = G3 ~ paid, data = student)  
  
Residuals:  
    Min       1Q   Median       3Q      Max   
-11.9508  -1.9508   0.0492   2.0492   7.0492   
  
Coefficients:  
            Estimate Std. Error t value Pr(>|t|)
```

```
(Intercept) 11.9508    0.1307  91.431   <2e-16 ***
paidyes     -0.7457    0.5332  -1.399    0.162
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.228 on 647 degrees of freedom
Multiple R-squared:  0.003014, Adjusted R-squared:  0.001473
F-statistic: 1.956 on 1 and 647 DF, p-value: 0.1624
```

```
# Koeffizienten ausgeben
coef(modpaid1)
```

```
(Intercept)    paidyes
11.9508197   -0.7456915
```

```
#Code zum Einfügen auf Dagitty.net für naives DAG ("#" vorab entfernen):

#dag {
#bb="-5.124,-9.299,4.964,10.134"
#G3 [outcome,pos="1.478,-0.493"]
#paid [exposure,pos="-0.787,-0.455"]
#paid -> G3
#}
```

Im naiven bivariaten Modell beträgt der Koeffizient für paidyes -0.746 . Schülerinnen und Schüler mit bezahltem Zusatzunterricht erzielen also deskriptiv im Mittel etwa 0.746 Punkte weniger als die Referenzgruppe ohne bezahlten Zusatzunterricht. Dieses Ergebnis ist jedoch noch nicht kausal interpretierbar, weil mögliche Drittvariablen vollständig ausgeblendet bleiben und darüber hinaus keine statistische Signifikanz vorliegt.

7.2 Adjustiertes Modell für paid

Schätzen Sie ein adjustiertes Modell mit den möglichen Confoundern studytime, absences, failures und higher. Erstellen Sie zuvor ein DAG mit den angenommenen theoretischen Zusammenhängen.

```
# Referenzkategorie festlegen
student$higher <- factor(student$higher, levels = c("no", "yes"))

# Adjustiertes Modell schätzen
modpaid2 <- lm(G3 ~ paid + studytime + absences + failures + higher + Medu + Fedu, data = student)

# Modellzusammenfassung ausgeben
summary(modpaid2)
```

```
Call:
lm(formula = G3 ~ paid + studytime + absences + failures + higher +
    Medu + Fedu, data = student)

Residuals:
    Min       1Q   Median       3Q      Max
-13.327  -1.524   0.094   1.740   6.284
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)	
(Intercept)	8.28540	0.49210	16.837	< 2e-16	***
paidyes	-0.78559	0.46976	-1.672	0.0949	.
studytime	0.61950	0.13682	4.528	7.10e-06	***
absences	-0.01235	0.02425	-0.509	0.6107	
failures	-1.52264	0.19968	-7.625	8.81e-14	***
higheryes	1.89240	0.38794	4.878	1.35e-06	***
Medu	0.29907	0.12930	2.313	0.0210	*
Fedu	0.17842	0.13253	1.346	0.1787	

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.808 on 641 degrees of freedom
Multiple R-squared: 0.2526, Adjusted R-squared: 0.2444
F-statistic: 30.95 on 7 and 641 DF, p-value: < 2.2e-16

```
# Koeffizienten ausgeben  
coef(modpaid2)
```

(Intercept)	paidyes	studytime	absences	failures	higheryes
8.28540050	-0.78558774	0.61949746	-0.01235015	-1.52263572	1.89240486
Medu	Fedu				
0.29906893	0.17842253				

#Code zum Einfügen auf Dagitty.net für adjustiertes DAG ("#" vorab entfernen):

```
#dag {  
#bb="-3.324,-3.601,3.254,3.573"  
#Fedu [adjusted,pos="2.497,1.625"]  
#G3 [outcome,pos="0.322,-0.469"]  
#Medu [adjusted,pos="-0.448,2.975"]  
#absences [adjusted,pos="-2.776,1.232"]  
#failures [adjusted,pos="2.706,-1.255"]  
#higher [adjusted,pos="0.385,-3.003"]  
#paid [exposure,pos="-0.879,-0.453"]  
#studytime [adjusted,pos="-2.572,-1.651"]  
#Fedu -> G3  
#Fedu -> paid  
#Medu -> G3  
#Medu -> paid  
#absences -> G3  
#absences -> paid  
#failures -> G3  
#failures -> paid  
#higher -> G3  
#higher -> paid  
#paid -> G3  
#studytime -> G3  
#studytime -> paid  
#}
```

Nach Adjustierung für die im DAG angenommenen Confounder studytime, absences, failures, higher, Medu und Fedu beträgt der Koeffizient für paidyes -0.786. Durch die Aufnahme dieser Variablen in das Regres-

sionsmodell werden die Backdoor-Pfade zwischen paid und G3 blockiert. Der Vergleich mit dem naiven Koeffizienten von -0.746 zeigt, dass sich der Zusammenhang nicht abschwächt, sondern leicht verstärkt. Ein positiver kausaler Effekt bezahlter Nachhilfe ist in diesen Daten damit nicht erkennbar. Außerdem ist der Effekt nicht statistisch signifikant.

8. Random Forest

8.1 Random Forest schätzen

Schätzen Sie einen Random Forest zur Vorhersage von Pass. Schließen Sie G1 und G2 aus.

Trainieren Sie den Random Forest auf 80 Prozent der Daten und testen Sie auf 20 Prozent der Daten.

Durch den Ausschluss von G1 und G2 soll vermieden werden, dass frühere Noten die Vorhersage von Pass nahezu vollständig dominieren. Trotzdem stehen noch zahlreiche schulische und soziale Merkmale zur Verfügung, sodass das Modell potenziell komplexe nichtlineare Zusammenhänge nutzen kann.

Interpretieren Sie die Ausgabe des Random Forest. Beurteilen Sie die Vorhersagegüte anhand der OOB-Fehlerrate sowie der Konfusionsmatrix und erläutern Sie, ob das Modell beide Klassen (yes und no) gleichermaßen gut vorhersagt.

```
# Zielvariable als Faktor codieren
student$Pass <- as.factor(student$Pass)

# Datensatz für Random Forest vorbereiten
studentrf <- student

# Direkte Zielvariable entfernen
studentrf$G3 <- NULL

# Datenaufteilung in Trainings- und Testdaten
set.seed(42)
trainIndex <- createDataPartition(studentrf$Pass, p = 0.8, list = FALSE)

trainData <- studentrf[trainIndex, ]
testData <- studentrf[-trainIndex, ]

# Reproduzierbarkeit
set.seed(42)

# Training des Random-Forest-Modells
modelrf <- randomForest(Pass ~ . - G1 - G2, data = trainData, importance = TRUE)

# Überblick über das Modell
modelrf
```

Call:

```
randomForest(formula = Pass ~ . - G1 - G2, data = trainData, importance = TRUE)
```

Type of random forest: classification

Number of trees: 500

No. of variables tried at each split: 4

OOB estimate of error rate: 16.15%

Confusion matrix:

	no	yes	class.error
no	16	64	0.80000000
yes	20	420	0.04545455

Das Modell weist eine OOB-Fehlerrate von 16,15 Prozent auf.

Die Konfusionsmatrix aus der Modellausgabe zeigt, dass die Klasse yes deutlich besser vorhergesagt wird als die Klasse no.

Für no liegt die klassenbezogene Fehlerrate bei 0.80, für yes dagegen nur bei 0.045.

Das Modell unterscheidet die beiden Klassen damit nicht gleich gut, sondern erkennt bestandene Fälle wesentlich zuverlässiger als nicht bestandene Fälle.

8.2 Modellgüte bewerten

Bewerten Sie die Güte des Random-Forest-Modells auf den Testdaten.

```
# Beobachtete Werte aus den Testdaten
test.obs <- testData$Pass

# Vorhersage auf den Testdaten
test.pred <- predict(modelrf, testData)

# Konfusionsmatrix ausgeben
confusionMatrix(test.pred, test.obs)
```

Confusion Matrix and Statistics

	Reference	
Prediction	no	yes
no	7	4
yes	13	105

Accuracy : 0.8682
95% CI : (0.7974, 0.9213)
No Information Rate : 0.845
P-Value [Acc > NIR] : 0.27759

Kappa : 0.3838

Mcnemar's Test P-Value : 0.05235

Sensitivity : 0.35000
Specificity : 0.96330
Pos Pred Value : 0.63636
Neg Pred Value : 0.88983
Prevalence : 0.15504
Detection Rate : 0.05426
Detection Prevalence : 0.08527
Balanced Accuracy : 0.65665

'Positive' Class : no

Auf den Testdaten erreicht das Modell eine Accuracy von 86,82 Prozent.

Dieser Wert liegt allerdings nur wenig über der No Information Rate von 84,50 Prozent.

Da no als positive Klasse definiert ist, beträgt die Sensitivity für Pass = no 35,00 Prozent, während die Specificity gegenüber Pass = yes bei 96,33 Prozent liegt.

Das Modell erkennt bestandene Fälle also sehr gut, nicht bestandene Fälle jedoch deutlich schlechter.

Die Konfusionsmatrix zeigt damit eine klare Schieflage zugunsten der häufigeren Klasse yes.

8.3 Variablenwichtigkeit interpretieren

Geben Sie die wichtigsten Prädiktoren des Random Forest aus.

```
# Wichtige Variablen  
importance(modelrf)
```


	no	yes	MeanDecreaseAccuracy	MeanDecreaseGini
school	17.9520361	6.4525390	14.8637464	9.490961
sex	3.4551087	-0.6798695	1.0864207	4.229374
Medu	-1.9774855	11.1224354	9.5122091	8.369898
Fedu	-0.5571078	7.0199795	6.3798163	8.349579
studytime	4.1301312	-3.5845218	-0.8987264	6.199072
failures	19.4348998	13.6912945	21.5332504	16.908364
paid	-2.5220783	5.1984344	3.6155713	1.879767
higher	13.6234289	11.7043758	16.7702684	11.190442
internet	-2.5486771	3.1138047	1.4250561	3.266283
famrel	6.2022959	4.0957776	6.3390949	9.998685
freetime	-1.5327683	-3.6411247	-3.7306317	9.350994
goout	-0.6872608	-3.5205702	-3.6966657	9.444610
Walc	2.3587232	1.4512832	2.4657398	10.318533
health	-2.0101376	0.5245294	-0.5932282	8.747659
absences	-2.3915228	-0.1752018	-1.5091140	13.251551
course	0.0000000	0.0000000	0.0000000	0.000000

```
# Sortierte Ausgabe nach MeanDecreaseAccuracy  
sort(importance(modelrf)[, "MeanDecreaseAccuracy"], decreasing = TRUE)
```

failures	higher	school	Medu	Fedu	famrel	paid
21.5332504	16.7702684	14.8637464	9.5122091	6.3798163	6.3390949	3.6155713
Walc	internet	sex	course	health	studytime	absences
2.4657398	1.4250561	1.0864207	0.0000000	-0.5932282	-0.8987264	-1.5091140
goout	freetime					
-3.6966657	-3.7306317					

```
# Grafik  
varImpPlot(modelrf)
```

modelrf



Die wichtigsten Prädiktoren im Random Forest sind nach dem Maß MeanDecreaseAccuracy vor allem failures, higher, school, Medu, Fedu und famrel.

Diese Variablen tragen am stärksten zur Vorhersagegenauigkeit des Modells bei.

Variablen wie freetime, goout, absences oder health zeigen dagegen keine positive Bedeutung für die Vorhersagegenauigkeit, da ihre Werte für MeanDecreaseAccuracy sehr klein oder sogar negativ ausfallen.

Inhaltlich deutet das darauf hin, dass vor allem bisherige schulische Problemlagen, Bildungsaspiration und familiäre Merkmale für das Bestehen relevant sind.